Livrable E2

Veille technique et règlementaire

Franck Le Fur

Le 30 Mars 2026

Titre professionnel **Développeur en intelligence artificielle**
de niveau 6 enregistré au RNCP sous le n°37827.

Passage par la voie de la formation - parcours de 19 mois achevé en mars 2026

Table des matières

1 Présentation **2**
- 1.1 Instructions du projet / Objectifs du Rapport . . . 2
- 1.2 Présentation du projet . . . 2
- 1.3 Introduction . . . 2
- 1.4 Applications . . . 3

2 Représentations Discrètes et Fréquentielles **5**
- 2.1 Encodage One-Hot . . . 5
- 2.2 Le Modèle Bag-of-Words (BoW) . . . 5
- 2.3 TF-IDF (Term Frequency-Inverse Document Frequency) . . . 5
  - 2.3.1 Comparaison BoW - TFIDF . . . 5
- 2.4 Les Limites Sémantiques des Méthodes Creuses . . . 6

3 Les Plongements Lexicaux Statiques et Prédictifs (Word Embeddings) **7**
- 3.1 Word2Vec : Architectures Neuronales Légères . . . 7
- 3.2 Architecture CBOW (Continuous Bag-of-Words) . . . 7
- 3.3 Architecture Skip-gram . . . 7
- 3.4 GloVe (Global Vectors for Word Representation) . . . 7
- 3.5 FastText : Robustesse par les Sous-Mots (Subword) . . . 8
- 3.6 La Limite de la Sémantique Statique . . . 8

4 L'Encodage Contextuel et des Transformers **9**
- 4.1 L'Architecture Transformer : Attention et Encodage Positionnel . . . 9
- 4.2 BERT (Bidirectional Encoder Representations from Transformers) . . . 9
- 4.3 GPT (Generative Pre-trained Transformer) . . . 9
- 4.4 La Divergence Fondamentale : Encodage vs. Génération . . . 10

5 Évaluation Rigoureuse et Métriques de Qualité des Vecteurs **11**
- 5.1 Cadre d'Évaluation : Intrinsèque vs. Extrinsèque . . . 11
- 5.2 Évaluation Intrinsèque Détaillée . . . 11
- 5.3 Les Benchmarks Standards : GLUE et SuperGLUE . . . 11

6 Défis Opérationnels, Éthiques et Perspectives d'Avenir **13**
- 6.1 Le Défi du Coût de Calcul . . . 13
- 6.2 Défis Éthiques : La Propagation des Biais . . . 13
- 6.3 Tendances Futures : Les LLMs Multimodaux . . . 13

7 Divers Infos **14**
- 7.1 Méthodes basées sur le texte brut . . . 15
- 7.2 Méthodes statistiques (bag-of-words) . . . 15
- 7.3 Méthodes basées sur les embeddings . . . 16
- 7.4 Méthodes avec Transformers (modèles contextuels) . . . 16
- 7.5 Divers . . . 16

8 Conclusion **17**

9 Latex Tools **18**

1 Présentation

1.1 Instructions du projet / Objectifs du Rapport

Un travail de recherche approfondi est demandé, listez les modèles utilisés, l'historique du sujet, les défis industriels que le domaine est susceptible de résoudre.
Pour chaque modèle réalisez une recherche complète :

- Expliquer les métriques utilisées pour tester et améliorer les modèles
- Listez les modèles/services déjà disponibles, comment ont-ils été entraînés, quelle volumétrié de données ?
- Expliquez les architectures utilisées, les fonction de perte, les techniques permettant de réduire l'overfitting etc.. Quelles méthodes récentes ont été utilisées ?
- Quelles sont les limites de chaque modèle/solution en place ?
- Quelles perspectives dans le futur ?
- Quels moyens sont nécessaires pour entraîner/faire l'inférence ?
- Présenter un panorama exhaustif des techniques d'encodage.
- Expliquer les principes, avantages et inconvénients de chaque méthode.
- Montrer l'évolution des approches (des méthodes "bag-of-words" aux embeddings contextuels).
- Aider à choisir la méthode adaptée à une tâche donnée.

1.2 Présentation du projet

Dans le cadre de mon sujet de société, le traitement du langage naturel a joué un rôle central. La question de l'encodage des textes s'est alors naturellement posée.

1.3 Introduction

Le Pont entre Langage et Calcul

1.1. Définition et Nécessité de la Vectorisation

Les ordinateurs travaillent exclusivement avec des 0 et des 1, si la conversion des nombres vers une représentatio binaire est naturelle, la consersion des données non-structurées en nombres est plus compliquée. Comment alors travailler avec des images ou du texte ?

La conversion d'images en nombres se fait assez naturellement si l'on considère une image comme un tableau de pixels et chaque pixel comme un vecteur numérique correspondant à la couleur RGB, la transparence etc ...

La vectorisation du texte est moins naturelle pourtant c'est ce qui permet aux ordinateurs de manipuler du texte et ainsi de traiter des tâches telles que :

L'encodage du texte en vecteurs numériques, ou vectorisation, constitue l'étape fondamentale et indispensable qui permet aux systèmes informatiques de Machine Learning de traiter et d'interpréter le langage humain. La machine, opérant intrinsèquement sur des nombres et des structures mathématiques, ne peut manipuler directement le langage, qui est symbolique et abstrait. La vectorisation crée ainsi un pont entre ces deux domaines.

Le Traitement Automatique du Langage Naturel (TALN) est le sous-domaine de l'Intelligence Artificielle (IA) spécifiquement dédié à l'interaction entre les ordinateurs et le langage humain. Pour que le TALN soit efficace, l'encodage doit capturer la complexité inhérente aux langues. Cette complexité se divise traditionnellement en trois dimensions : la syntaxe, qui régit l'agencement et la structure des mots dans une phrase ; la sémantique, qui correspond à la

signification des mots et des groupes de mots ; et la phonologie, essentielle pour les systèmes de reconnaissance vocale, qui s'occupe des sonorités de la langue orale
L'encodage du texte en nombres est une étape essentielle dans le domaine du traitement automatique du langage naturel (TALN) car, fondamentalement, les machines sont incapables de traiter les données textuelles brutes. Pour que les algorithmes d'apprentissage automatique, y compris les réseaux neuronaux, puissent fonctionner, ils exigent que le texte soit transformé en un format numérique, généralement sous forme de vecteurs.

L'utilité de cette conversion se manifeste à travers plusieurs avantages techniques et d'applications :

1. Représentation du Sens et des Relations L'objectif principal de l'encodage, notamment par les plongements lexicaux (word embeddings ou plongements sémantiques), est de représenter les mots de manière à capturer leur signification et leurs relations sémantiques. • Principe sémantique : Le plongement lexical (ou sémantique) représente chaque mot par un vecteur de nombres réels. La technique est basée sur l'hypothèse que les mots qui apparaissent dans des contextes similaires ont des significations apparentées. • Proximité et analogie : La distance et la direction entre les vecteurs numériques reflètent la similarité et les relations entre les mots correspondants. Par conséquent, des mots de sens similaire (comme "chien" et "chat") sont représentés par des vecteurs proches. Cette disposition permet de reproduire des schémas sémantiques et syntaxiques par arithmétique vectorielle, comme l'équation "roi - homme + femme = reine". • Contextualisation : Les modèles de langage modernes, comme BERT, utilisent l'encodage pour effectuer une analyse contextuelle des mots, ce qui leur donne plus de facilité à gérer les ambiguïtés et les termes polysémiques en fonction du contexte dans lequel ils apparaissent.

2. Efficacité et Performance Technique

Transformer le texte en vecteurs améliore considérablement l'efficacité des modèles d'apprentissage automatique : • Réduction de la dimensionnalité : Les plongements lexicaux sont des vecteurs denses de dimension inférieure. Contrairement aux méthodes traditionnelles qui utilisent des vecteurs creux (comme l'encodage one-hot qui a une dimension égale à la taille du vocabulaire et contient beaucoup de zéros), les plongements réduisent la complexité des calculs et les besoins en mémoire, ce qui est crucial pour les applications de TALN à grande échelle. • Généralisation : L'approche permet aux modèles de bien généraliser aux mots inconnus ou rares (out-of-vocabulary), car elle leur permet de représenter ces mots en fonction de leur contexte ou de leur structure en sous-mots (comme dans FastText). • Apprentissage accéléré : Les modèles entraînés avec des plongements de mots ont tendance à converger plus rapidement et à être plus performants que ceux utilisant des représentations creuses.

1.4 Applications

Les embedding permettent de transformer les mots, phrases ou même des documents entiers, images ou fichiers audio en vecteurs/ matrices numériques, qui capturent la sémantique et les relations contextuelles des termes.
L'encodage numérique est le fondement de presque toutes les tâches de traitement du langage naturel :

— Classification de texte : Il est utilisé pour l'analyse des sentiments, la détection des spams, et la catégorisation des sujets.

— Traduction et Génération : Les plongements lexicaux sont essentiels dans les systèmes de traduction automatique pour comprendre les relations sémantiques entre les mots des langues source et cible. Ils sont également utilisés dans la modélisation du langage et la génération de séquences de sortie cohérentes.

— Extraction d'informations : Ils contribuent à la reconnaissance d'entités nommées (NER) en aidant les modèles à comprendre le contexte et les relations entre les mots pour identifier et classer des entités.

— Systèmes interactifs : Ils sont au cœur des chatbots, des assistants virtuels et des systèmes de questions-réponses.

— Recherche d'information : L'encodage en vecteurs permet la recherche vectorielle, qui améliore la mise en correspondance des requêtes utilisateur avec les documents pertinents, augmentant ainsi la précision des moteurs de recherche.

— Base pour modèles avancés : Les plongements lexicaux pré-entraînés servent de base à des architectures plus sophistiquées comme BERT et GPT, permettant un apprentissage par transfert efficace à partir de vastes corpus de données.

Dans un système RAG, les embeddings sont utilisés pour retrouver des informations pertinentes dans un corpus de données avant de générer une réponse.

Le LLM, tel que GPT-3, GPT-4, Gemini, Mistral ou autre, utilise ces informations récupérées pour contextualiser et enrichir sa génération de texte, offrant ainsi des réponses plus informées et précises que celles générées à partir de connaissances internes du modèle uniquement.

L'efficacité d'un système RAG dépend largement de la qualité des embeddings utilisés.

Un bon modèle d'embedding doit être capable de capturer les subtilités sémantiques du langage et de les représenter dans un espace vectoriel de manière à ce que les distances ou similarités entre vecteurs correspondent à des relations sémantiques logiques.

Par exemple, les mots "roi" et "reine" devraient être plus proches entre eux dans l'espace vectoriel que "roi" et "pomme", reflétant leur proximité sémantique dans la langue réelle.

2 Représentations Discrètes et Fréquentielles

Cette première ère de vectorisation se caractérise par l'utilisation de représentations "creuses" (sparse), où la dimensionnalité est proportionnelle à la taille du vocabulaire et où la grande majorité des valeurs vectorielles est nulle.

2.1 Encodage One-Hot

Le One-Hot Encoding est l'approche la plus élémentaire. Chaque mot unique du vocabulaire (V) se voit attribuer un vecteur de dimension V. Ce vecteur est binaire, contenant un 1 à la position correspondant à ce mot spécifique et des 0 partout ailleurs. Le principal inconvénient de cette méthode est qu'elle ne permet de capturer aucune relation sémantique entre les mots. Mathématiquement, le produit scalaire entre deux vecteurs One-Hot différents est toujours nul, ce qui signifie que toutes les paires de mots sont considérées comme orthogonales. De plus, la taille du vecteur explose avec l'augmentation du vocabulaire, rendant les modèles peu évolutifs.

2.2 Le Modèle Bag-of-Words (BoW)

Le modèle Bag-of-Words (BoW), ou "Sac de Mots," représente un document entier en ignorant l'ordre et la syntaxe des mots.4 Le vecteur du document est construit en comptant la fréquence d'apparition de chaque mot du vocabulaire dans ce document. Bien que simple et couramment utilisé pour la classification de documents où l'ordre est secondaire, BoW souffre toujours de la même limitation sémantique que le One-Hot : il ne distingue pas la signification des mots ou leur relation, seulement leur présence et leur fréquence brute.

2.3 TF-IDF (Term Frequency-Inverse Document Frequency)

TF-IDF est une amélioration statistique du BoW qui vise à pondérer l'importance des mots. La méthode combine deux facteurs :

Term Frequency (TF) : La fréquence d'apparition d'un terme dans un document.

Inverse Document Frequency (IDF) : L'inverse de la fréquence du document, mesurant à quel point un terme est rare ou commun à travers l'ensemble du corpus.

Le score TF-IDF est le produit de ces deux composantes. Ce mécanisme réduit l'importance des mots trop courants (les mots-outils, ou stop words) qui apparaissent dans presque tous les documents. Par conséquent, TF-IDF permet une meilleure identification des mots discriminants qui caractérisent un document donné.

2.3.1 Comparaison BoW - TFIDF

Bag-Of-Words compte combien de fois un mot apparait dans un document, alors que TF-IDF calcule la fréquence des mots (relativement aux autres documents)

Ces méthodes ne tiennent pas compte de l'ordre des mots ni de la sémantique.

Quand utiliser BoW ?

- Pour des tâches simples de classification (topic modeling)
- Avec de petits Dataset
- Lorsque l'on veut une représentation simple pour faire de l'exploration de données

Quand utiliser TF-IDF ?

-

https://www.geeksforgeeks.org/nlp/bag-of-words-vs-tf-idf/

2.4 Les Limites Sémantiques des Méthodes Creuses

Bien que TF-IDF représente un progrès statistique, toutes les méthodes creuses partagent une contradiction structurelle fondamentale : elles attribuent des identifiants (indices) aux mots sans encoder de signification intrinsèque. Elles ne peuvent pas inférer de similarité sémantique.

Par exemple, statistiquement, les mots "voiture" et "automobile" sont traités comme deux entités distinctes et orthogonales, même s'ils partagent une signification quasi identique.

Ce manque de sémantique et la haute dimensionnalité des vecteurs creux freinent leur utilisation dans le contexte du Deep Learning. Pour que les architectures neuronales puissent efficacement apprendre des représentations, une réduction de la dimensionnalité (vecteurs denses) est nécessaire, menant à l'ère des plongements lexicaux statiques.

3 Les Plongements Lexicaux Statiques et Prédictifs (Word Embeddings)

L'ère des plongements lexicaux a introduit les représentations "denses," où chaque mot est associé à un vecteur de faible dimensionnalité (typiquement entre 50 et 300), dont toutes les valeurs sont des nombres réels continus.

3.1 Word2Vec : Architectures Neuronales Légères

Word2Vec est un ensemble de modèles introduits par Mikolov et al. qui utilisent des réseaux de neurones peu profonds (deux couches) pour apprendre des vecteurs en reconstruisant les contextes linguistiques des mots. L'objectif est que les mots partageant des contextes communs se retrouvent proches dans l'espace vectoriel, capturant ainsi les similarités sémantiques et syntaxiques.

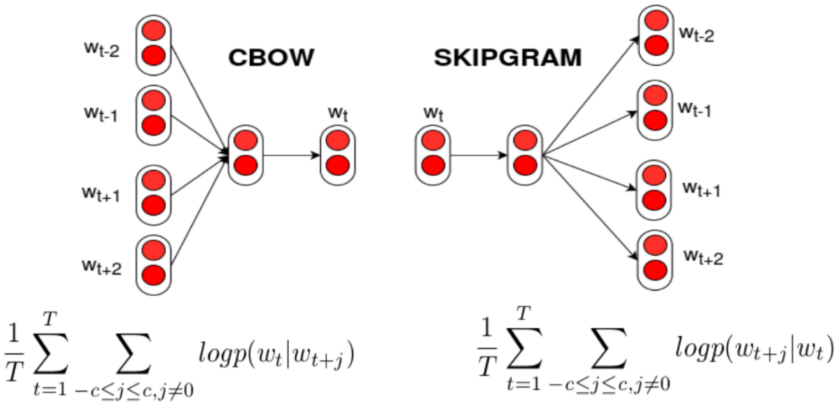

3.2 Architecture CBOW (Continuous Bag-of-Words)

Dans l'approche CBOW, la tâche consiste à prédire le mot central à partir de la somme vectorielle de ses mots voisins dans une fenêtre de contexte donnée.3 Le modèle peut être vu comme une tâche de "remplissage du blanc".3 CBOW est généralement plus rapide à entraîner que Skip-gram.

3.3 Architecture Skip-gram

Le modèle Skip-gram inverse la tâche de CBOW : il utilise le mot central pour prédire les mots qui l'entourent (son contexte). L'idée directrice est que le vecteur d'un mot doit être proche du vecteur de chacun de ses voisins. L'architecture Skip-gram attribue plus de poids aux mots contextuels proches qu'aux mots distants. Techniquement, pour chaque mot du corpus, l'encodage One-Hot du mot est utilisé comme entrée du réseau neuronal. La sortie est une distribution de probabilité sur le dictionnaire, représentant une prédiction des mots individuels dans le voisinage du mot central. L'entraînement vise à maximiser la probabilité de ce contexte.3 Selon les créateurs, Skip-gram est plus efficace pour obtenir des représentations de qualité pour les mots peu fréquents.

3.4 GloVe (Global Vectors for Word Representation)

GloVe, développé par Stanford, a été conçu comme un concurrent de Word2Vec. Sa philosophie est de combiner les forces des méthodes fréquentielles globales (basées sur des matrices de co-occurrence) et des méthodes prédictives locales.

Mécanisme de Co-occurrence

GloVe est un algorithme non supervisé qui génère des représentations denses en s'entraînant sur des statistiques agrégées de co-occurrence de mots à l'échelle du corpus.

Comptage des Co-occurrences : La matrice de co-occurrence X est construite, où X_{ij} est le nombre de fois où le mot j apparaît dans le contexte du mot i.3Modélisation Probabiliste : Le modèle cherche à apprendre deux vecteurs, w_i et $\tilde{w}_i$, pour chaque mot i, de sorte que leur produit scalaire, ajusté par des biais, approxime le logarithme de la probabilité de co-occurrence $P_{ij} = P(j|i)$. La relation clé est la régression log-bilinéaire :

$$w_i^T \tilde{w}_j + b_i + \tilde{b}_j \approx \ln P_{ij}$$

.

Optimisation : L'apprentissage est effectué en minimisant une fonction de perte quadratique pondérée. La pondération est cruciale pour que les co-occurrences fréquentes aient plus d'influence que les co-occurrences rares et potentiellement bruitées. La fonction de perte minimisée est :

$$L = \sum_{i,j \in V} f(X_{ij})(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \ln P_{ij})^2$$

.3 Une fois entraîné, la représentation finale recommandée pour le mot i est la somme de ses deux vecteurs, $w_i + \tilde{w}_i$.

3.5 FastText : Robustesse par les Sous-Mots (Subword)

Le problème majeur des plongements statiques comme Word2Vec et GloVe est leur incapacité à générer des vecteurs pour les mots hors-vocabulaire (OOV, Out-of-Vocabulary), car ils attribuent un vecteur unique à chaque mot entier vu pendant l'entraînement. FastText surmonte cette limitation en utilisant une approche basée sur les sous-mots (ou n-grammes de caractères). Si un mot OOV ou rare est rencontré, FastText génère son plongement en sommant les vecteurs des n-grammes de caractères qui le composent.

Cette approche offre deux avantages majeurs :

Gestion OOV : Même un mot entièrement nouveau peut être encodé de manière significative si ses fragments (ses n-grammes) ont été vus pendant l'entraînement.

Morphologie et Rareté : FastText est particulièrement robuste pour les langues riches en morphologie (où les mots changent beaucoup par flexion ou conjugaison) et pour les fautes de frappe ou les mots rares, car il exploite l'information au niveau des caractères.

3.6 La Limite de la Sémantique Statique

Malgré les avancées de Word2Vec, GloVe et FastText en termes de similarité sémantique, ils partagent un défaut fondamental : ils sont statiques. Chaque mot se voit attribuer un vecteur unique, ignorant le contexte spécifique de son apparition.

Cette contrainte empêche la résolution de la polysémie (ambiguïté sémantique). Par exemple, le mot "banque" aura le même vecteur, qu'il désigne un établissement financier ou le bord d'une rivière. Les modèles statiques ne peuvent représenter que la "sémantique moyenne" du mot dans le corpus. La nécessité de générer un vecteur dynamique pour chaque instance d'un mot, en fonction de son environnement phrastique, a conduit à l'avènement des modèles contextuels basés sur les Transformers.

4 L'Encodage Contextuel et des Transformers

L'introduction de l'architecture Transformer a marqué la troisième ère de la vectorisation, permettant des représentations dynamiques et contextuelles.

4.1 L'Architecture Transformer : Attention et Encodage Positionnel

Le Transformer a révolutionné le TALN en s'affranchissant des réseaux neuronaux récurrents (RNNs), qui traitaient l'information séquentiellement. Le cœur du Transformer est le mécanisme d'auto-attention (Self-Attention), qui permet au modèle de pondérer l'importance de tous les autres mots de la séquence lors du traitement d'un mot donné, se concentrant ainsi sur les parties pertinentes du texte.

Puisque le mécanisme d'auto-attention traite les mots simultanément, l'information inhérente à l'ordre séquentiel est perdue. Pour remédier à cela, l'encodage positionnel est intégré à l'architecture. Il s'agit d'un ajout de vecteurs qui introduit la notion de position relative et absolue des mots dans la séquence, information vitale pour la compréhension de la syntaxe et du contexte.

4.2 BERT (Bidirectional Encoder Representations from Transformers)

Développé par Google en 2018, BERT est un modèle pré-entraîné qui utilise l'encodeur du Transformer. Sa principale innovation est son caractère bidirectionnel : il analyse le contexte d'un mot en regardant simultanément ce qui précède (contexte gauche) et ce qui suit (contexte droit).

4.2.1. Résolution de la Polysémie La bidirectionnalité confère à BERT une capacité de compréhension contextuelle complète pour chaque mot. Contrairement aux modèles statiques, BERT génère un vecteur unique et dynamique pour chaque apparition du mot dans une phrase donnée. Par conséquent, il peut attribuer des vecteurs différents au mot "banque" selon qu'il apparaît dans le contexte de "bord de la rivière" ou "ouverture de compte," résolvant ainsi la polysémie.

4.2.2. Tâches de Pré-entraînement BERT est pré-entraîné sur deux tâches principales pour maximiser sa capacité de compréhension :

Masked Language Model (MLM) : Le modèle doit prédire des mots masqués dans la phrase à partir du contexte environnant.

Next Sentence Prediction (NSP) : Le modèle doit prédire si une phrase B suit logiquement une phrase A. Cela permet au modèle de comprendre les dépendances et les relations qui existent entre des phrases consécutives.

Grâce à ces innovations, BERT a rapidement établi des performances de pointe (SOTA, State-of-the-Art) sur de nombreux benchmarks de compréhension (GLUE, SQuAD). Des variantes ont été développées pour optimiser les performances ou les ressources, telles que RoBERTa (optimisation de l'entraînement), DistilBERT (version allégée, 40% plus rapide pour 97% des performances) et CamemBERT (modèle spécifiquement entraîné pour la langue française).

4.3 GPT (Generative Pre-trained Transformer)

Les modèles de la série GPT, développés par OpenAI, sont des modèles génératifs basés sur le décodeur du Transformer. Leur fonctionnement est intrinsèquement unidirectionnel : ils regardent uniquement le contexte précédent (gauche) pour prédire le mot suivant.

Cette structure unidirectionnelle les rend excellents pour la génération de texte cohérent, créatif et dans des styles variés , mais moins aptes à la compréhension discriminative fine que

les modèles bidirectionnels comme BERT. GPT est également reconnu pour sa polyvalence et sa capacité à effectuer du few-shot learning (apprentissage avec très peu d'exemples).

4.4 La Divergence Fondamentale : Encodage vs. Génération

La conception des modèles basés sur les Transformers reflète une divergence stratégique en TALN. L'encodeur bidirectionnel (BERT) est optimisé pour les tâches discriminatives (analyse, classification, réponse aux questions), car il nécessite une vue complète de la séquence pour déterminer le contexte d'un mot. En revanche, le décodeur unidirectionnel (GPT) est optimisé pour la génération séquentielle, imitant la manière dont le langage est naturellement produit.

Cette divergence est cruciale sur le plan industriel : tandis que BERT est la référence pour l'analyse fine (classification, NER), GPT est le moteur des interfaces conversationnelles et de la création de contenu.

5 Évaluation Rigoureuse et Métriques de Qualité des Vecteurs

Évaluation Rigoureuse et Métriques de Qualité des VecteursL'évaluation de la qualité des plongements lexicaux est fondamentale pour valider leur utilité sémantique. Elle se divise en deux cadres méthodologiques complémentaires.

5.1 Cadre d'Évaluation : Intrinsèque vs. Extrinsèque

L'évaluation intrinsèque teste les propriétés des vecteurs eux-mêmes, mesurant leur cohérence mathématique par rapport aux relations linguistiques (par exemple, la similarité et l'analogie). Elle est indépendante d'une application finale spécifique.L'évaluation extrinsèque, en revanche, mesure la performance du modèle vectoriel lorsqu'il est utilisé comme fonctionnalité d'entrée dans une tâche aval spécifique (downstream task), telle que la classification de sentiments, la traduction automatique, ou la réponse aux questions (Q et A).

5.2 Évaluation Intrinsèque Détaillée

Cette métrique utilise des ensembles de données annotées par des humains (comme WordSim353) pour comparer la distance cosinus entre les vecteurs de deux mots à la similarité perçue par l'être humain.16 Un bon plongement lexical doit garantir que la proximité géométrique des vecteurs reflète la proximité sémantique.

Par exemple, la similarité sémantique entre les concepts 'President' et 'City' devrait être proche de zéro.

Analogies et CatégorisationLes tâches d'analogies testent si les relations linéaires (opérations vectorielles) correspondent aux relations linguistiques (ex : 'Roi' - 'Homme' + 'Femme' ≈ 'Reine').16La métrique de catégorisation aligne un regroupement (clustering) de mots basé sur leurs vecteurs avec des catégories prédéfinies.

Détection de ParaphrasesCette évaluation, souvent considérée comme une forme d'évaluation intrinsèque de haut niveau, utilise des benchmarks comme Quora Question Pairs (QQP) ou MRPC pour déterminer si les plongements peuvent identifier des expressions qui sont sémantiquement équivalentes.

5.3 Les Benchmarks Standards : GLUE et SuperGLUE

Pour standardiser l'évaluation extrinsèque, des benchmarks synthétiques ont été créés :GLUE (General Language Understanding Evaluation) : Ce benchmark initial offrait une métrique unique pour résumer les progrès sur neuf tâches diversifiées de compréhension du langage.

SuperGLUE : L'efficacité rapide des modèles basés sur les Transformers, qui ont rapidement approché ou dépassé les performances des humains non-experts sur GLUE, a nécessité la création de SuperGLUE.

SuperGLUE propose un nouvel ensemble de tâches de compréhension plus difficiles, exigeant des capacités de raisonnement contextuel plus sophistiquées.19Le remplacement rapide de GLUE par SuperGLUE démontre l'accélération exponentielle des progrès dans l'encodage contextuel. Cela révèle que les modèles modernes maîtrisent largement les tâches sémantiques simples (comme les analogies) et que l'évaluation doit désormais se concentrer sur des tâches extrinsèques complexes (raisonnement, inférence) pour mesurer la véritable compréhension générale du langage.

Tableau Comparatif des Architectures d'EncodageÈre/ModèleNature de la RepréSentationMécanisme Contexte/SémantiqueRésolution de la PolysémieI. BoW/TF-IDFCreuse (Sparse)Fréquence

Un titre de colonne	Un autre titre	Un dernier
à gauche	centré	à droite
d	e	f

FIGURE 1 – *Un tableau simple*

statistiqueNulleII. Word2Vec/GloVeDense (Statique)Prédiction/Co-occurrence locale ou globaleFaible (un seul vecteur)II. FastTextDense (Statique/Subword)N-grammes de caractèresFaibleIII. BERT (Transformer)Dense (Dynamique)Auto-attention BidirectionnelleExcellente (vecteur par instance)III. GPT (Transformer)Dense (Dynamique)Auto-attention UnidirectionnelleBonne (vecteur par instance)

6 Défis Opérationnels, Éthiques et Perspectives d'Avenir

6.1 Le Défi du Coût de Calcul

L'évolution vers l'encodage contextuel de haute fidélité s'est accompagnée d'une augmentation spectaculaire des ressources requises. La construction d'un Grand Modèle de Langage (LLM) à partir de zéro, tel que le GPT-3 (estimé à 175 milliards de paramètres), nécessite une puissance de calcul colossale, des ressources financières importantes et beaucoup de temps. Cette barrière de coût limite l'accès à la création de modèles fondateurs à quelques organisations disposant de ressources massives.

Pour adresser ce problème, notamment lors de l'inférence, des modèles optimisés ont été développés. Par exemple, DistilBERT réduit la taille et le temps d'inférence de BERT tout en maintenant une grande partie de ses performances, améliorant ainsi la productivité et réduisant le coût opérationnel.

6.2 Défis Éthiques : La Propagation des Biais

Les modèles d'encodage vectoriel sont entraînés sur d'énormes volumes de données textuelles issues d'Internet. Ces corpus intègrent et amplifient les préjugés et les stéréotypes sociaux existants (liés au genre, à la race, etc.).

L'impact de ces préjugés est significatif, affectant potentiellement les utilisateurs du modèle et la société dans son ensemble, en conduisant à des résultats discriminatoires ou injustes dans des applications critiques. Les biais sont encodés directement dans la structure de l'espace vectoriel (par exemple, des associations stéréotypées entre métiers et genres).

Le coût exorbitant du pré-entraînement mène à une concentration du développement des LLMs fondamentaux. Cela signifie qu'un petit nombre d'organisations détermine, par leurs choix de données et d'architecture, la structure sémantique et les biais inhérents qui seront répercutés dans l'espace vectoriel utilisé par des milliers d'applications tierces. L'atténuation de ces biais nécessite des efforts de débiaisement des données d'entraînement et des ajustements des pondérations du modèle.

6.3 Tendances Futures : Les LLMs Multimodaux

L'avenir de l'encodage vectoriel se dirige vers la multimodalité, où les Large Multimodal Models (LMMs) intègrent le texte avec d'autres modalités de données, principalement la vision (images et vidéo) et l'audio.

7.3.1. Architectures Clés Des modèles pionniers comme CLIP (Contrastive Language-Image Pre-training) utilisent l'apprentissage contrastif pour aligner les espaces vectoriels du langage et de l'image, permettant au modèle d'associer des concepts textuels à des représentations visuelles. D'autres, comme Flamingo, combinent un encodeur visuel dédié avec un modèle de langage.

7.3.2. Applications Les LMMs ouvrent des possibilités d'innovation quasi illimitées. Les applications concrètes incluent :

La génération d'images à partir de descriptions textuelles.

L'analyse en temps réel de vidéos, permettant de déduire des émotions ou des actions basées à la fois sur le dialogue et les expressions visuelles.

Le marketing personnalisé, synchronisant les vecteurs de texte et les visuels pour créer des publicités ciblées.

La convergence des capacités de traitement du langage naturel et d'analyse d'image transforme profondément l'interaction entre l'homme et la machine.

7 Divers Infos

Partie 1 : Les Fondations - Méthodes Basées sur le Lexique (Bag-of-Words et variantes)

Principe général : Ces méthodes ignorent l'ordre des mots et se concentrent sur leur présence ou leur fréquence dans un document. Elles créent un "sac" de mots.

1.1. One-Hot Encoding - Concept : Représenter chaque mot par un vecteur binaire de la taille du vocabulaire, où un seul élément est à 1 (celui correspondant au mot) et tous les autres à 0. - Exemple : Vocabulaire = ["chat", "chien", "mange"] -> "chat" = [1, 0, 0], "chien" = [0, 1, 0] - Avantages : Simplicité de mise en œuvre. - Inconvénients : - Vecteurs de très haute dimension (problème de "malédiction de la dimension"). - Aucune notion de similarité entre les mots (tous les vecteurs sont orthogonaux). - Ignore complètement la sémantique et l'ordre des mots.

1.2. Encodage par Comptage (Count Vectorization) - Concept : Étendre le one-hot encoding au niveau du document. Chaque document est représenté par un vecteur où chaque dimension correspond à la fréquence d'un mot du vocabulaire. - Représentation : Matrice Document-Termes (Document-Term Matrix). - Avantages : Simple, conserve une notion d'importance par la fréquence. - Inconvénients : - Les mots très fréquents (et souvent peu informatifs comme "le", "de") dominent la représentation. - Toujours aucune sémantique.

1.3. TF-IDF (Term Frequency-Inverse Document Frequency) - Concept : Amélioration du simple comptage en pondérant la fréquence des termes. - TF (Term Frequency) : Fréquence du terme dans le document. - IDF (Inverse Document Frequency) : Mesure de l'importance du terme dans l'ensemble du corpus. Un mot présent dans tous les documents (ex : "le") a un IDF faible. - Calcul : 'TF-IDF(t, d) = TF(t, d) * log(N / DF(t))' où N est le nombre total de documents. - Avantages : - Réduit l'importance des mots trop communs (stop-words). - Donne plus de poids aux mots "spécifiques" et informatifs d'un document. - Inconvénients : - Ne capture toujours pas la sémantique ni l'ordre des mots. - Performances mitigées pour des tâches complexes comme la traduction ou la synthèse.

Partie 2 : La Révolution Sémantique - Les Word Embeddings (Représentations Denses)

Principe général : Représenter chaque mot par un vecteur dense (de dimension fixe et réduite, ex : 50 à 300) dans un espace vectoriel continu. L'idée clé est que les mots avec des significations similaires ont des vecteurs similaires.

2.1. Principes Fondamentaux des Word Embeddings - Hypothèse de Distribution (Harris, 1954) : "Un mot est caractérisé par les compagnons qu'il fréquente". Les mots apparaissant dans des contextes similaires ont des significations similaires.

2.2. Méthodes Pré-entraînées Classiques - Word2Vec (Mikolov et al., 2013) - Deux architectures : - CBOW (Continuous Bag-of-Words) : Prédit un mot cible à partir de son contexte. - Skip-gram : Prédit le contexte à partir d'un mot cible (généralement plus performant pour les mots rares). - Caractéristiques : Rapide à entraîner, efficace sur de grands corpus.

- GloVe (Global Vectors for Word Representation, 2014) - Concept : Combine les avantages des méthodes de décomposition matricielle (comme LSA) et des méthodes de fenêtre contextuelle locale (comme Word2Vec). - Fonctionnement : Utilise les statistiques globales de co-occurrence des mots sur l'ensemble du corpus. - Avantage : Capture souvent mieux les relations globales que Word2Vec.

- FastText (de Facebook AI, 2016) - Innovation : Représente les mots comme des sacs de caractères n-grammes. Le vecteur d'un mot est la somme des vecteurs de ses n-grammes. - Avantage majeur : Peut générer des vecteurs pour des mots hors-vocabulaire (non vus lors de l'entraînement), ce qui est crucial pour les langues riches en morphologie ou pour gérer les fautes de frappe.

Partie 3 : L'Ère Contextuelle - Les Encodages par Transformeurs

Principe général : Au lieu d'avoir un vecteur fixe pour chaque mot, la représentation d'un

mot dépend du contexte dans lequel il apparaît dans une phrase. Le mot "banque" n'aura pas le même encodage dans "je vais à la banque" et "je m'assois sur la banque".

3.1. La Rupture : L'Architecture Transformer - Introduction de "Attention is All You Need" (Vaswani et al., 2017). - Mécanisme d'Auto-Attention : Permet à chaque mot d'interagir avec tous les autres mots de la phrase pour calculer une représentation contextuelle. - Avantage : Capture les dépendances à longue distance et les relations complexes entre les mots, quel que soit leur position dans la phrase.

3.2. Modèles Pré-entraînés Emblématiques (Pré-training / Fine-tuning) - BERT (Bidirectional Encoder Representations from Transformers) - Innovation : Entraînement bidirectionnel (contrairement à GPT qui est unidirectionnel). Il regarde tout le contexte à gauche et à droite du mot masqué. - Tâches de pré-entraînement : Masquage de mots (MLM) et prédiction de la phrase suivante (NSP). - Utilisation : Génère des embeddings contextuels pour chaque token (mot ou sous-mot) dans une phrase.

- Les Modèles de la Famille GPT (Generative Pre-trained Transformer) - Principe : Architecture de décodeur uniquement, entraînée de manière auto-régressive (prédit le prochain token en ne regardant que les tokens précédents). - Force : Excellents pour la génération de texte.

- Autres Modèles Importants** (à mentionner brièvement) : RoBERTa, XLNet, T5, etc.

3.3. Méthodologie d'Encodage avec les Transformeurs - Tokenization : Découpage du texte en tokens (souvent des sous-mots, ex : "playing" -> "play" + "ing") à l'aide d'algorithmes comme WordPiece (BERT) ou Byte-Pair Encoding (GPT). - Principe d'inférence : Pour obtenir l'encodage d'une phrase, on la passe dans le modèle. La couche de sortie (ou une couche cachée) fournit un vecteur contextuel pour chaque token. - Pooling : Pour obtenir un vecteur pour une phrase/texte entier, on peut moyenner (mean pooling) les vecteurs de tous les tokens, ou utiliser le token spécial '[CLS]' (dans BERT).

Partie 4 : Synthèse Comparative et Guide de Sélection

4.1. Tableau Récapitulatif Comparatif

OOV = Out-Of-Vocabulary (mots non vus lors de l'entraînement)*

4.2. Comment Choisir la Bonne Méthode ? - Tâche simple (ex : classification de sentiments, détection de spam) : TF-IDF ou Word Embeddings statiques (Word2Vec) peuvent suffire et sont peu coûteux. - Tâche complexe (ex : compréhension de question, résumé de texte, traduction) : Les modèles contextuels (BERT et similaires) sont indispensables. - Besoins en ressources (CPU/GPU, temps) : Les méthodes non-contextuelles sont beaucoup plus rapides et moins gourmandes. - Taille du jeu de données : Sur un petit jeu de données, utiliser des embeddings pré-entraînés est crucial. Sur un très grand jeu de données, on peut envisager de fine-tuner un modèle comme BERT. - Langue et domaine : Choisir un modèle pré-entraîné dans la bonne langue et, si possible, sur un domaine proche (ex : BioBERT pour la biomédecine).

7.1 Méthodes basées sur le texte brut

Similarité lexicale

— Jaccard Similarity : Compare le ratio des mots communs entre deux textes. Idéal pour les ensembles de mots (ex : tags, mots-clés).

— Levenshtein Distance : Mesure le nombre d'éditions (ajout/suppression/remplacement) pour passer d'un texte à l'autre. Utile pour la similarité de chaînes courtes (ex : correction orthographique).

7.2 Méthodes statistiques (bag-of-words)

— TF-IDF + Similarité cosinus : Représente les textes comme des vecteurs de poids TF-IDF, puis calcule la similarité cosinus.

— BM25 (Okapi BM25) : Amélioration de TF-IDF pour la recherche d'information, mieux adaptée aux documents longs. Librairie : rank_bm25.

7.3 Méthodes basées sur les embeddings

— Word Embeddings (moyennés) : Moyenne des embeddings des mots (Word2Vec, GloVe, FastText).

— Sentence Embeddings : Sentence-BERT (SBERT) : Modèle dédié pour encoder des phrases.

— Universal Sentence Encoder (USE) : Version allégée disponible via TensorFlow Hub.

—

7.4 Méthodes avec Transformers (modèles contextuels)

— Similarité via [CLS] token (BERT-like) : Utilise le vecteur du token [CLS] de BERT pour représenter le texte.

— Modèles spécialisés en similarité : MPNet, RoBERTa STS : Modèles fine-tunés sur des tâches de similarité sémantique (ex : STSb). Cross-Encoders : Compare deux textes simultanément (précis mais lent).

Quelle méthode choisir ?

Cas d'usage	Méthode recommandée
Texte court, rapidité	Jaccard, TF-IDF + Cosinus
Sémantique profonde	Sentence-BERT, Cross-Encoders
Ressources limitées	Word2Vec/GloVe moyennés
Similarité à grande échelle	FAISS + SBERT

7.5 Divers

BLEU Score (bilingual evaluation understudy) : mesure la qualité d'une traduction de texte.
ROUGE Score (Recall-Oriented Understudy for Gisting Evaluation) : mesure la qualité des résumés automatiques.
Métriques RAGAS

8 Conclusion

Conclusion
1. Récapitulatif de l'Évolution : Du simple comptage de symboles (Bag-of-Words) à la capture de sens statique (Word Embeddings) puis à la compréhension contextuelle profonde (Transformers). 2. L'État de l'Art : Aujourd'hui, les encodeurs contextuels basés sur les Transformers sont la référence pour la plupart des tâches de NLP, car ils capturent la nuance et la polysémie du langage. 3. Perspectives Futures : Tendances vers des modèles encore plus grands (LLMs - Large Language Models), plus efficaces, et plus spécialisés. L'encodage multimodal (texte + image) est également un champ de recherche très actif.

9 Latex Tools

footnote [1]
référence bibliographique [2], [1]

Lien vers section (voir section ...)
Lien vers les métriques RAGAS.

voici une ancre

1. https://keras.io/api/layers/core_layers/embedding/

Références

[1] José Siqueira de Cerqueira, Kai-Kristian Kemell, Rebekah Rousi, Nannan Xi, Juho Hamari, and Pekka Abrahamsson. Mapping trustworthiness in large language models : A bibliometric analysis bridging theory to practice, 2025.

[2] Zihang Li, Yangdong Ruan, Wenjun Liu, Zhengyang Wang, and Tong Yang. Cft-rag : An entity tree based retrieval augmented generation algorithm with cuckoo filter, 2025.