Introduction au Traitement du Langage Naturel (NLP)

Partie 1 : Concepts de base et évolution

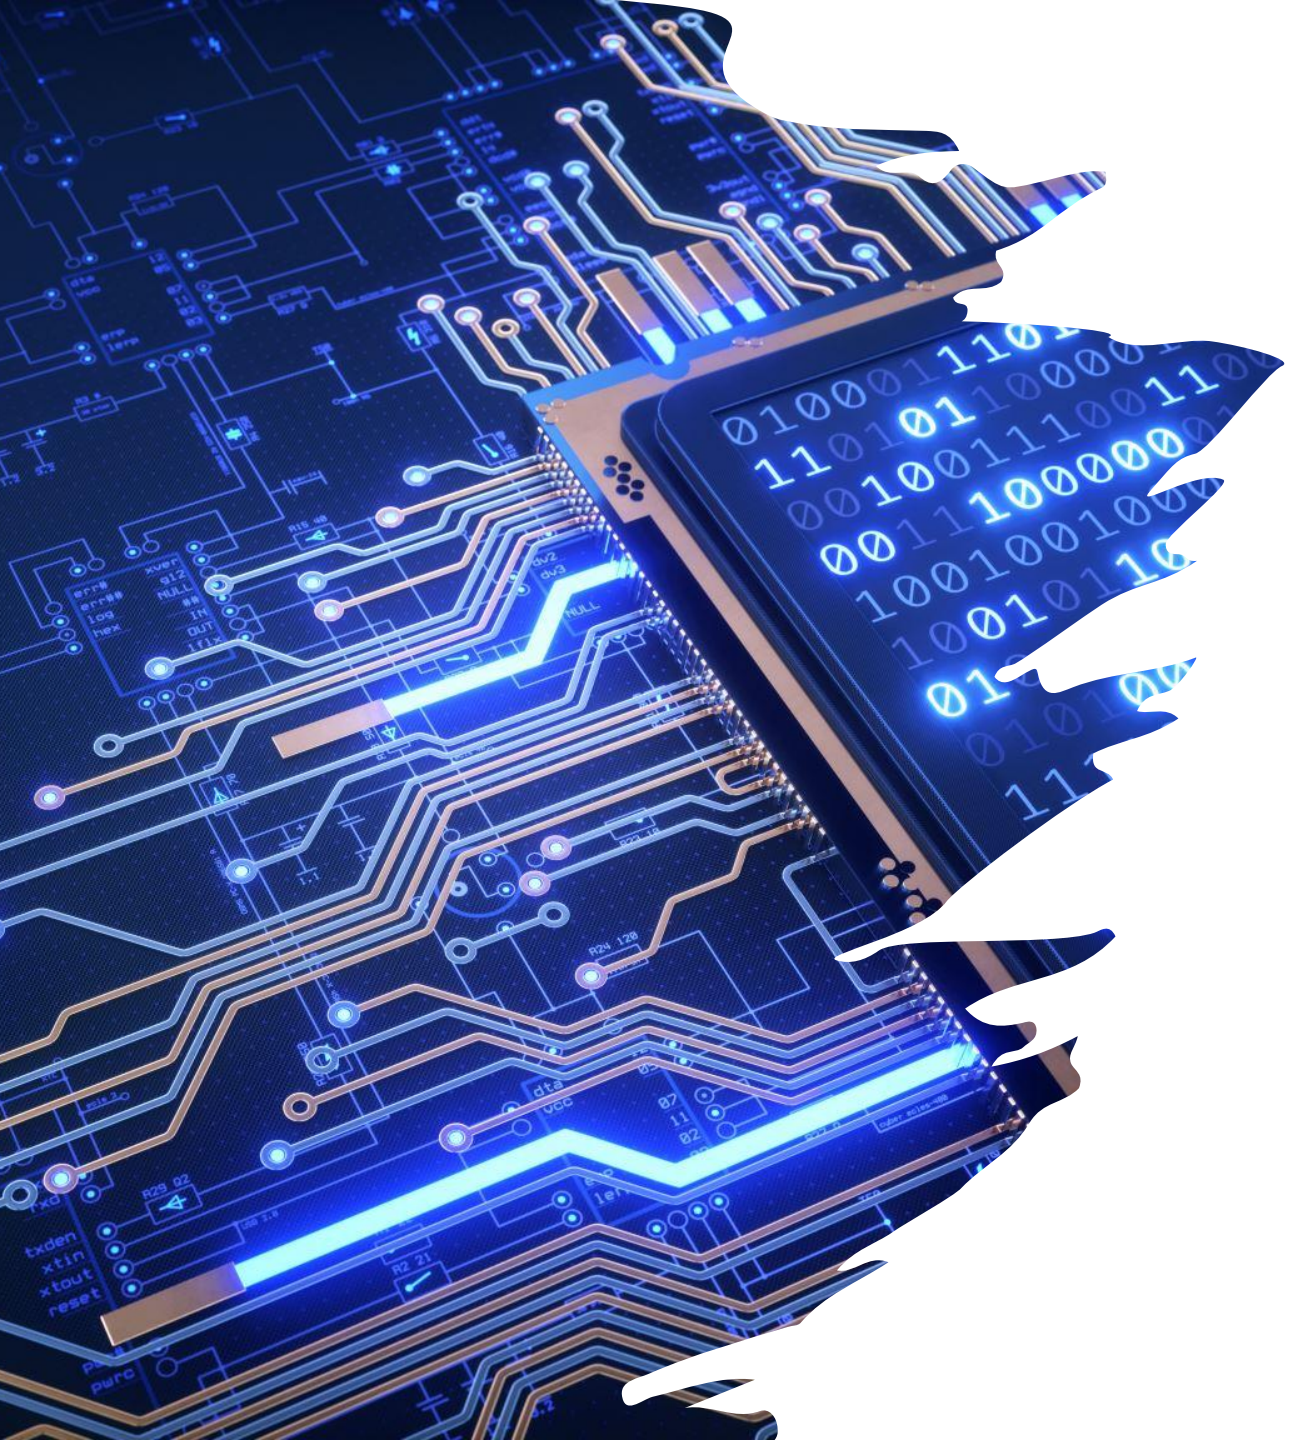

Définition du NLP

- Le **traitement du langage naturel** est une branche de l'intelligence artificielle qui se concentre sur l'interaction entre les ordinateurs et le langage humain.

- Le NLP vise à permettre aux ordinateurs de comprendre, interpréter, manipuler et générer du langage humain de manière naturelle et significative.

Tâches remplies par le NLP

- **Analyse syntaxique et morphologique** : Détecter et analyser la structure grammaticale des phrases, y compris la reconnaissance des parties du discours, l'analyse de la structure de la phrase, et l'identification des entités et de leurs relations.
- **Analyse sémantique** : Comprendre la signification des mots dans le contexte et la signification globale des phrases, y compris la résolution de l'ambiguïté sémantique et la compréhension des références et des implications.
- **Traitement des sentiments et des émotions** : Identifier et classer les opinions et les sentiments exprimés dans le texte pour déterminer les attitudes et les réactions des utilisateurs.
- **Résumé automatique** : Générer des résumés concis de longs documents ou de données textuelles.

Tâches remplies par le NLP

- **Traduction automatique** : Traduire du texte ou de la parole d'une langue à une autre.
- **Reconnaissance vocale et génération de la parole** : Convertir la parole en texte et vice versa.
- **Dialogue et interaction homme-machine** : Permettre des conversations naturelles entre les utilisateurs et les systèmes informatiques, comme les chatbots et les assistants virtuels.
- **Extraction d'informations** : Identifier et extraire des informations spécifiques à partir de textes, telles que les noms, les lieux, les dates et d'autres données pertinentes.

Pourquoi étudier le NLP pour un MLOps?

- **Compréhension des applications du NLP :** Le NLP est un domaine clé de l'IA et présente de nombreuses applications pratiques. Comprendre ces applications aide les ML Ops à mieux cerner les besoins et les défis spécifiques des projets de NLP.
- **Gestion de projets complexes :** Les projets de NLP ont tendance à être particulièrement complexes en raison de la nature subtile et diversifiée du langage humain. Apprendre à gérer ces projets prépare les ML Ops à des défis uniques, comme le traitement de grandes quantités de données textuelles et la gestion des subtilités linguistiques.
- **Déploiement et maintenance :** Les ML Ops doivent connaître les meilleures pratiques pour déployer et maintenir des modèles de NLP en production. Cela comprend la gestion des mises à jour des modèles, la surveillance de la performance, et l'assurance de la qualité des données d'entrée.

Pourquoi c’est compliqué le NLP ?

L’ambiguïté du langage

Le langage humain est intrinsèquement ambigu. Les mots peuvent avoir plusieurs significations, et le contexte joue un rôle crucial pour déterminer leur sens exact. Cette ambivalence sémantique rend le traitement du langage naturel particulièrement délicat.

Pourquoi c’est compliqué le NLP ?

Des règles grammaticales et syntaxiques variées

Chaque langue a ses propres règles grammaticales et structures syntaxiques, souvent complexes et subtiles. L'application de ces règles dans le NLP est un défi majeur, d'autant plus qu'elles varient considérablement d'une langue à l'autre.

Pourquoi c’est compliqué le NLP ?

L’importance du contexte pour comprendre le langage

Les mêmes mots ou phrases peuvent avoir des significations différentes selon le contexte dans lequel ils sont utilisés. Les systèmes de NLP doivent être capables de saisir et d'analyser ce contexte, ce qui est loin d'être simple.

Pourquoi c’est compliqué le NLP ?

Figures de style et langage non littéral

Les humains utilisent souvent des figures de style comme les métaphores, l'ironie et le sarcasme. Ces éléments peuvent être extrêmement difficiles à interpréter pour les systèmes de NLP.

Histoire du NLP

1. **Années 1950-1960 : Naissance et Pionniers** - Le NLP émerge dans le contexte académique avec des recherches en linguistique informatique. Les premières expérimentations comprennent la traduction automatique, comme le projet Georgetown-IBM de 1954.
2. **Années 1970 : Premières Applications** - L'accent est mis sur les règles grammaticales et la compréhension du langage => systèmes basés sur des règles.
3. **Années 1980 : Approche Symbolique** - L'approche symbolique, centrée sur la logique et les règles définies par l'homme, domine. => système SHRDLU
4. **Années 1990 : Émergence du Machine Learning** - Avec l'avènement du machine learning, le NLP commence à utiliser des statistiques pour traiter le langage, menant à des améliorations significatives en traduction automatique et en reconnaissance vocale.
5. **Début des années 2000 : Modèles Statistiques Avancés** - Les modèles comme les Hidden Markov Models (HMM) et les Conditional Random Fields (CRF) sont utilisés pour des tâches complexes comme l'étiquetage de parties du discours et l'analyse syntaxique.
6. **Années 2010 : Révolution du Deep Learning** - L'introduction de réseaux de neurones profonds transforme le NLP, améliorant considérablement la qualité de la traduction automatique, de la reconnaissance vocale et de la génération de texte.
7. **Milieu des années 2010 : Modèles de Langage Pré-entraînés** - Des modèles comme BERT et GPT émergent, offrant des performances sans précédent en compréhension du langage naturel grâce à l'apprentissage sur de vastes quantités de texte.

Applications du NLP dans la vie quotidienne

- Assistants Virtuels
- Traduction Automatique
- Service Client (Chatbots et agents virtuels)
- Réseaux Sociaux et Analyse des Sentiments
- Recommandations de Contenu

Applications du NLP dans la vie quotidienne

- **Sécurité et Surveillance**
- **Santé et Recherche Médicale**
- **Éducation et Apprentissage en Ligne**
- **Accessibilité**

Comment structurer le texte pour en faire du ML/DL ?

Pour effectuer des analyses statistiques, ou construire un modèle de *Machine Learning*, il est nécessaire de se ramener à des données structurées (un “tableau” de données).

Comment faire pour apporter une structure aux textes non structurés ?

Avant de structurer, il va falloir nettoyer le langage naturel pour le rationnaliser au maximum

Introduction au Traitement du Langage Naturel (NLP)

Partie 2 : Le prétraitement du langage naturel (Moins de vocabulaire, moins de bruit)

Vocabulaire

- **Corpus** : l’ensemble des textes d’un jeu de données
- **Document** : chaque texte du corpus
- **Token** : unité de texte : mot, partie de mot, groupe de mots, phrase
- **Tokenisation** : découper un document en *tokens*
- **Vocabulaire** : ensemble des *tokens* distincts présents dans un corpus.

Tokenisation et Lemmisation

- La tokenisation est un processus fondamental dans le traitement du langage naturel (NLP). Elle consiste à découper un texte en unités plus petites, appelées « tokens ».
- Le principe de la tokenisation est de simplifier et de structurer le texte pour une analyse ultérieure.

Tokenisation et Lemmisation

1. **Découpage du Texte**
2. **Standardisation**
3. **Élimination de la ponctuation et des caractères spéciaux**
4. **Traitement des exceptions**
5. **Lemmisation** (Réduction d'un mot à sa forme de base ou forme dictionnaire, appelée lemme)

Tokenisation

Le traitement automatique du langage naturel vise à créer des outils de traitement de la langue naturelle pour diverses applications.

le | traitement | automatique | du | langage | naturel | vise | à | créer
des | outils | de | traitement | de | la | langue | naturelle | pour
diverses | applications | .

Retrait des stop words

le | traitement | automatique | du | langage | naturel | vise | à | créer
des | outils | de | traitement | de | la | langue | naturelle | pour
diverses | applications | .

traitement | automatique | langage | naturel | vise | créer | outils | traitement
langue | naturelle | diverses | applications

Lemmatisation (+ tokenisation et stopwords)

Le traitement automatique du langage naturel vise à créer des outils de traitement de la langue naturelle pour diverses applications.

traiter | automatique | langue | naturel | viser | créer | outil | traiter
langue | naturel | divers | application

Tokenisation

Le traitement automatique du langage naturel vise à créer des outils de traitement de la langue naturelle pour diverses applications.

le | traitement | automatique | du | langage | naturel | vise | à | créer

des | outils | de | traitement | de | la | langue | naturelle | pour

diverses | applications | .

Retrait des stop words

le | traitement | automatique | du | langage | naturel | vise | à | créer

des | outils | de | traitement | de | la | langue | naturelle | pour

diverses | applications | .

traitement | automatique | langage | naturel | vise | créer | outils | traitement

langue | naturelle | diverses | applications

Lemmatisation (+ tokenisation et stopwords)

Le traitement automatique du langage naturel vise à créer des outils de traitement de la langue naturelle pour diverses applications.

traiter | automatique | langue | naturel | viser | créer | outil | traiter

langue | naturel | divers | application

Tokenisation et Lemmisation

1. **Découpage du Texte**
2. **Standardisation**
3. **Élimination de la ponctuation et des caractères spéciaux**
4. **Traitement des exceptions**
5. **Lemmisation** (Réduction d'un mot à sa forme de base ou forme dictionnaire, appelée lemme)

A vous de jouer !

Vous avez 1h pour faire du nettoyage de langage naturel :

Consigne : faites un notebook de tokenization puis de lemmatisation du premier avis contenu dans le « Train » du dataset « Allocine » de Huggingface.

Ressources :

- Spacy : site et documentation
- Datasets de Hugging Face : site et documentation
- Pas de ChatBot, pas de Google, pas de Jérémie !

Tokenisation demandée :

- tous les tokens en minuscule

- enlever les ponctuations, les espaces, les stopwords

Lemmatisation demandée :

- pour les plus avancés remplacer le mot « Paris » par « Brest »

Introduction au Traitement du Langage Naturel (NLP)

Partie 3 : Le NLP avant le Deep Learning

Les Bag-of-Words (BoW)

Processus :

1. **Prétraitement** et **Tokenisation**
2. **Création d'un Dictionnaire** : Un dictionnaire est créé avec tous les mots uniques présents dans le corpus (ensemble de documents textuels). Chaque mot unique obtient un index dans ce dictionnaire.
3. **Vectorisation** : Chaque document du corpus est représenté par un vecteur. La longueur de ce vecteur correspond au nombre total de mots uniques dans le dictionnaire. Si un mot du dictionnaire apparaît dans le document, la position correspondante dans le vecteur est incrémentée.

Chaque document devient donc un vecteur

Les Bag-of-Words (BoW)

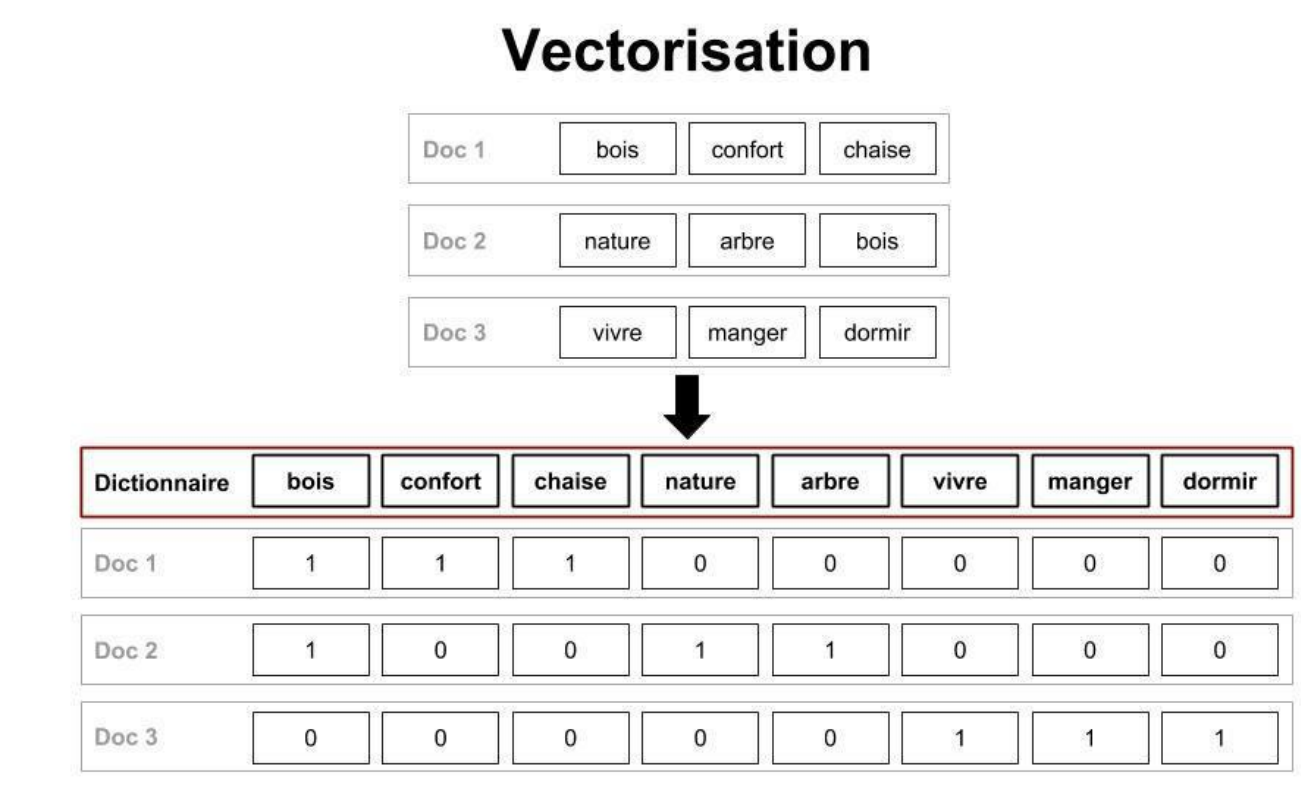

Les Bag-of-Words (BoW)

Chaque document devient donc un vecteur

On peut donc ensuite utiliser une méthode de ML classique pour effectuer :

- **De l'analyse de sentiment**
- **De la détection de spam**
- **De la classification de documents**
- **Clustering**

=> Exemple : Une régression logistique, un random forest, SVM, etc…

Term Frequency-Inverse Document Frequency (TF-IDF)

- Le TF-IDF("Term Frequency-Inverse Document Frequency«)cherche à évaluer l'importance d'un mot dans un document par rapport à un ensemble de documents ou un "corpus".

- Cette approche améliore le BoW en insistant sur les mots clefs d'un document par rapport au corpus => recherche de similarité plus efficace

$$w_{x,y} = tf_{x,y} \times \log\left(\frac{N}{df_x}\right)$$

TF-IDF

Term x within document y

$tf_{x,y}$ = frequency of x in y

df_x = number of documents containing x

N = total number of documents

Le traitement automatique du langage naturel vise à créer des outils de traitement de la langue naturelle pour diverses applications.

traiter | automatique | langue | naturel | viser | créer | outil | traiter

langue | naturel | divers | application

Il y a de plus en plus de traitements naturels permettant de soigner les plantes de son jardin et de protéger la nature.

traiter | naturel | permettre | soigner | plante | jardin | protéger | nature

$$w_{x,y} = tf_{x,y} \times \log\left(\frac{N}{df_x}\right)$$

TF-IDF

Term x within document y

$tf_{x,y}$ = frequency of x in y

df_x = number of documents containing x

N = total number of documents

Lemme	TF phrase 1	TF phrase 2	IDF	TF-IDF phrase 1	TF-IDF phrase 2
traiter	2/12	1/8	0	0	0
automatique	1/12	0	0.7	0.06	0
langue	2/12	0	0.7	0.12	0
naturel	2/12	1/8	0	0	0
viser	1/12	0	0.7	0.06	0
créer	1/12	0	0.7	0.06	0
outil	1/12	0	0.7	0.06	0
divers	1/12	0	0.7	0.06	0
application	1/12	0	0.7	0.06	0
permettre	0	1/8	0.7	0	0.08
soigner	0	1/8	0.7	0	0.08
plante	0	1/8	0.7	0	0.08
jardin	0	1/8	0.7	0	0.08
protéger	0	1/8	0.7	0	0.08
nature	0	1/8	0.7	0	0.08

Bow

2	1
1	0
2	0
2	1
1	0
1	0
1	0
1	0
1	0
0	1
0	1
0	1
0	1
0	1
0	1

Modèles n-grammes

- Les modèles n-grammes sont une technique fondamentale en traitement du langage naturel (NLP). Ils sont utilisés pour prédire le mot suivant dans une séquence de mots, en se basant sur les mots précédents. Voici comment ils fonctionnent :

1. **Définition d'un n-gramme** : Un "n-gramme" est une séquence de 'n' éléments (généralement des mots) tirés d'un texte ou d'une parole. Par exemple, dans un bigramme (2-gramme), chaque séquence se compose de deux mots consécutifs. De même, un trigramme (3-gramme) se compose de trois mots consécutifs.

2. **Construction du Modèle** : Pour construire un modèle n-gramme, le texte est d'abord divisé en n-grammes. Par exemple, la phrase "Le chat dort" donnerait les bigrammes suivants : ["Le chat", "chat dort"].

3. **Calcul des Probabilités** : Le modèle calcule la probabilité d'apparition de chaque n-gramme dans le corpus. Pour un bigramme, par exemple, cela reviendrait à calculer la probabilité d'un mot étant donné le mot précédent.

4. **Utilisation des Probabilités** : Ces probabilités sont ensuite utilisées pour prédire le mot suivant dans une séquence de mots. Dans un modèle bigramme, la prédiction du mot suivant dépend uniquement du mot précédent. Dans un trigramme, elle dépend des deux mots précédents, et ainsi de suite.

5. **Chaînage des n-grammes** : Les modèles n-grammes peuvent être chaînés pour générer du texte. Après avoir choisi un mot de départ, le modèle utilise les probabilités pour générer successivement les mots suivants.

6. **Limites** : Bien que les modèles n-grammes soient utiles pour capturer les dépendances locales entre les mots, ils ont des limites. Ils ne tiennent pas compte du contexte plus large et peuvent devenir très volumineux et inefficaces en termes de stockage lorsque 'n' est grand.

7. **Lissage et Réduction de la Dimensionnalité** : Pour gérer le problème des n-grammes non observés dans le corpus d'entraînement (ce qui peut conduire à une probabilité nulle), des techniques de lissage sont utilisées. De plus, des approches comme la réduction de la dimensionnalité peuvent être employées pour gérer la taille et la complexité des modèles.

- Les modèles n-grammes sont largement utilisés dans diverses applications de NLP, telles que la correction orthographique, la reconnaissance vocale, et la génération de texte. Leur simplicité et leur efficacité pour certaines tâches les rendent précieux, malgré leurs limitations en matière de compréhension contextuelle plus profonde.

Introduction au Traitement du Langage Naturel (NLP)

Partie 4 : Méthodes modernes en NLP

L’apport du Deep Learning au NLP

1. Compréhension contextuelle améliorée
2. Qualité de la traduction automatique
3. Modèles de langages
4. Génération de texte, traitement de la parole et reconnaissance

Le Word Embedding ou plongement lexical

- Le Word Embedding est une technique de représentation du langage où **les mots sont transformés en vecteurs de nombres réels dans un espace à haute dimension.**
- Contrairement à des représentations plus simples comme le Bag of Words ou TF-IDF, **les embeddings capturent des relations sémantiques et syntaxiques plus riches entre les mots.**

Exemple : En BoW : « la souris mange le chat » a le même vecteur que « le chat mange la souris »

Le Word Embedding ou plongement lexical

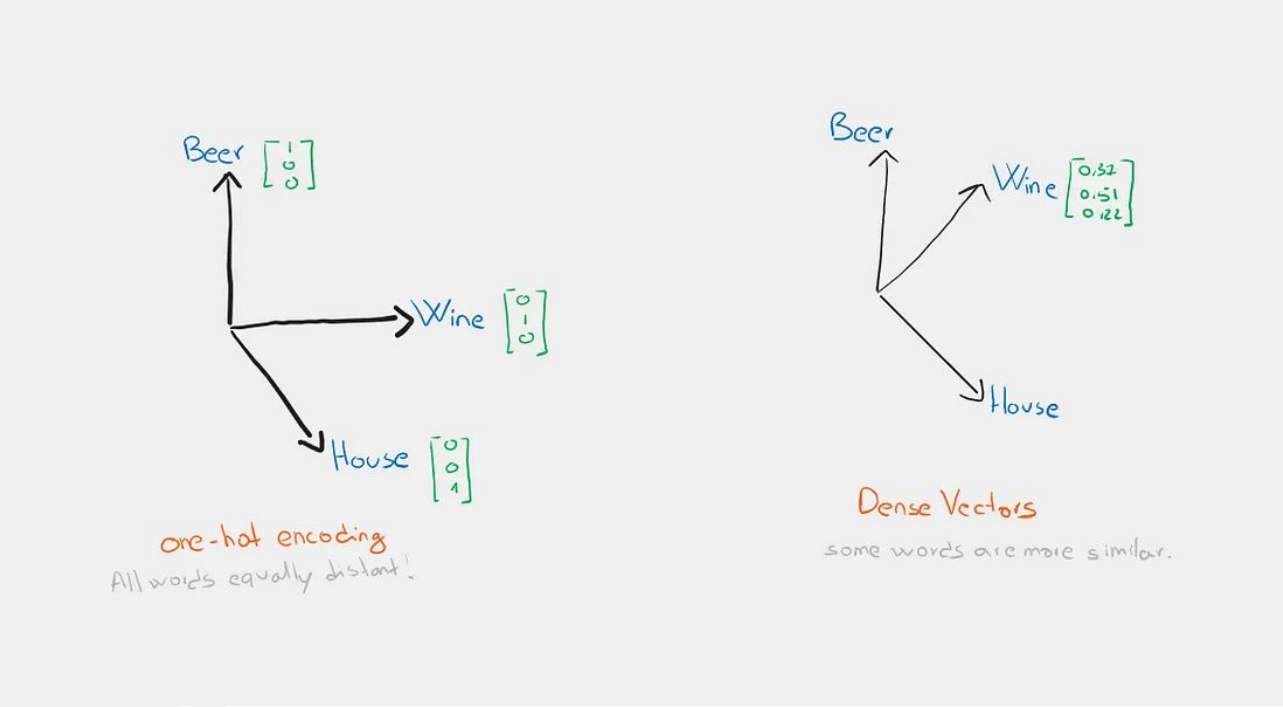

Le Word Embedding ou plongement lexical

- Origine dans le Deep Learning
- Amélioration de la performance des modèles de NLP
- Réduction de la dimensionnalité
- Capture des relations sémantiques
- Base pour des modèles plus avancés

Word2Vec : un réseau de neurones avec 1 seule couche cachée

Word2vec (Google,2013)

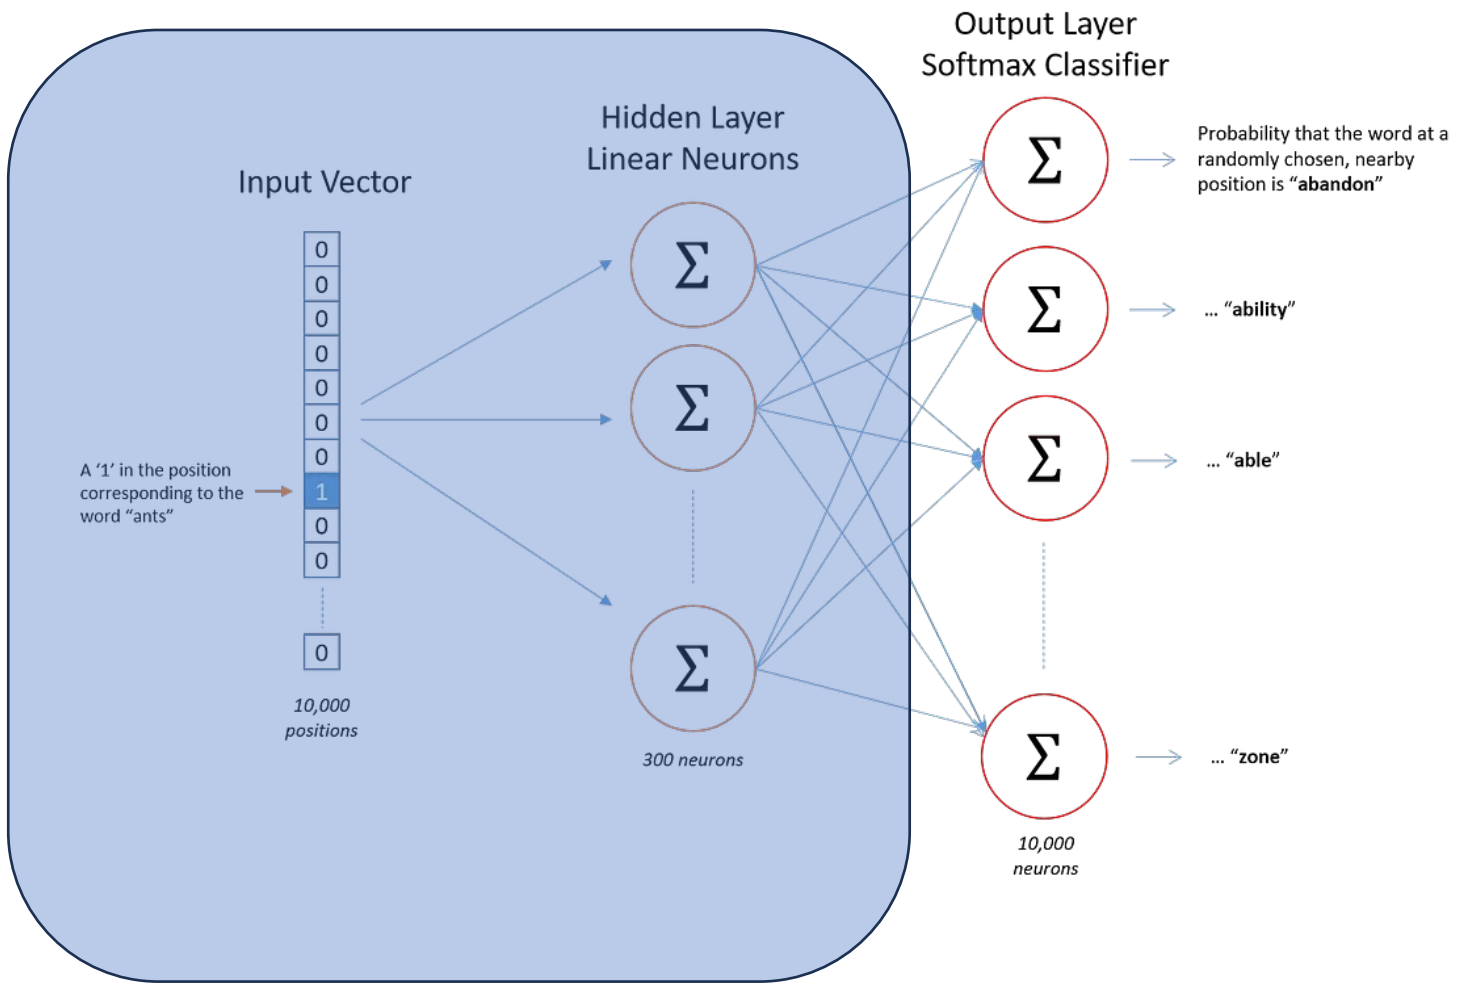

Plongement lexical

Word2vec (Google,2013)

- **Le contexte compte :**
- Jérome a été percuté par un …..
- Jérome a été percuté par un …. bus

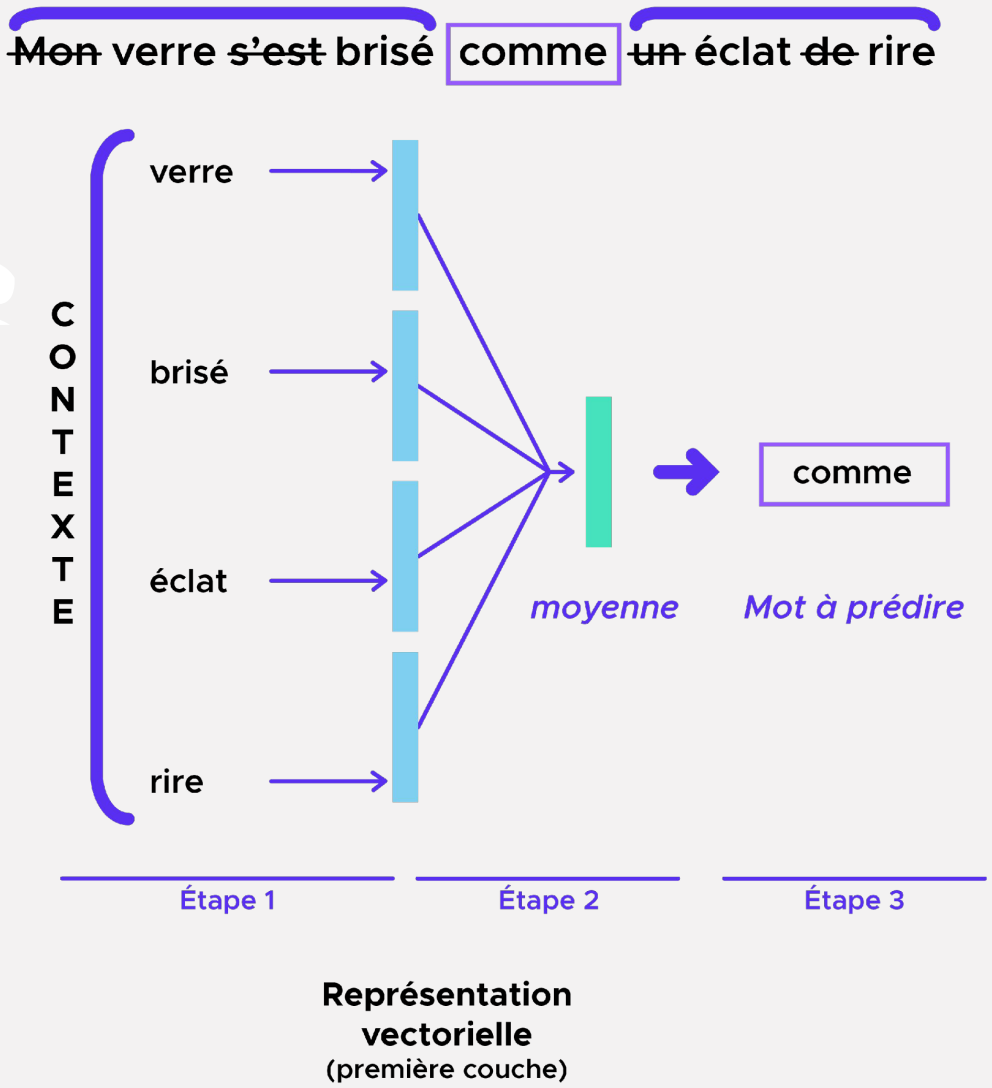

Word2vec (Google,2013)

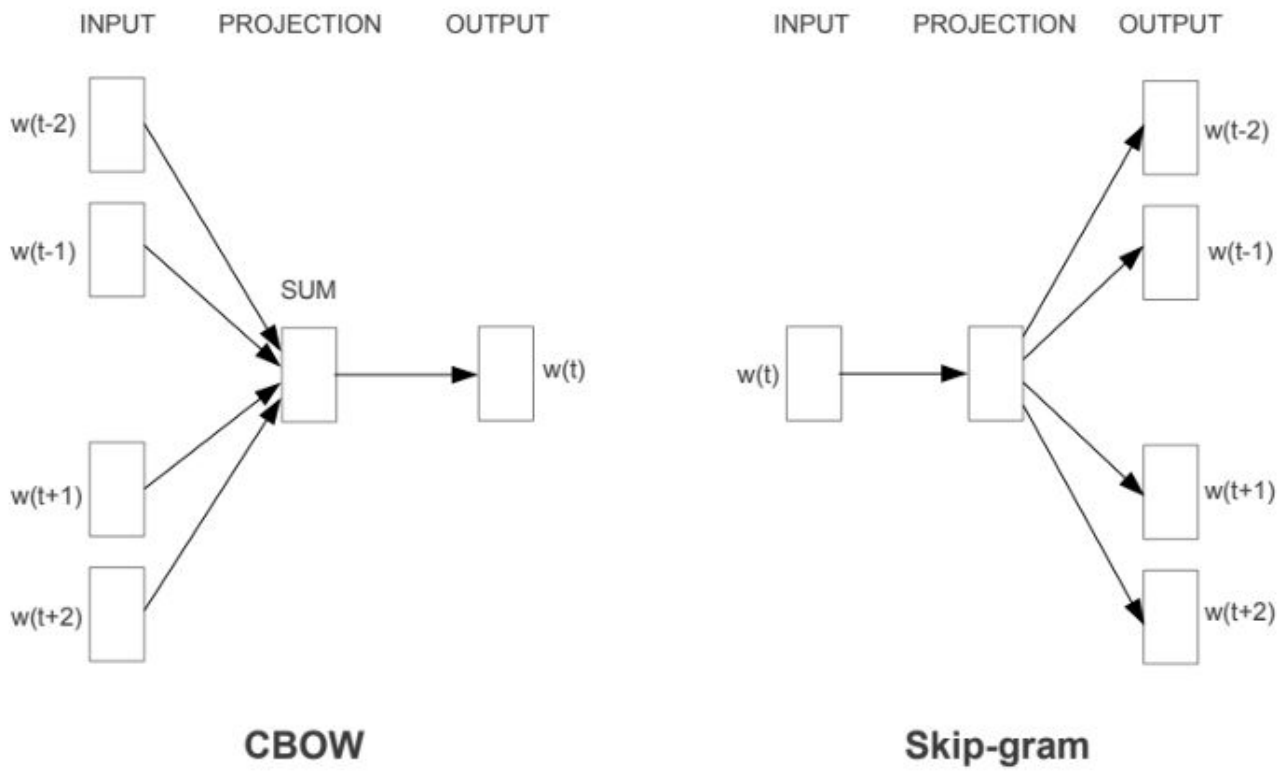

Word2vec (Google,2013)

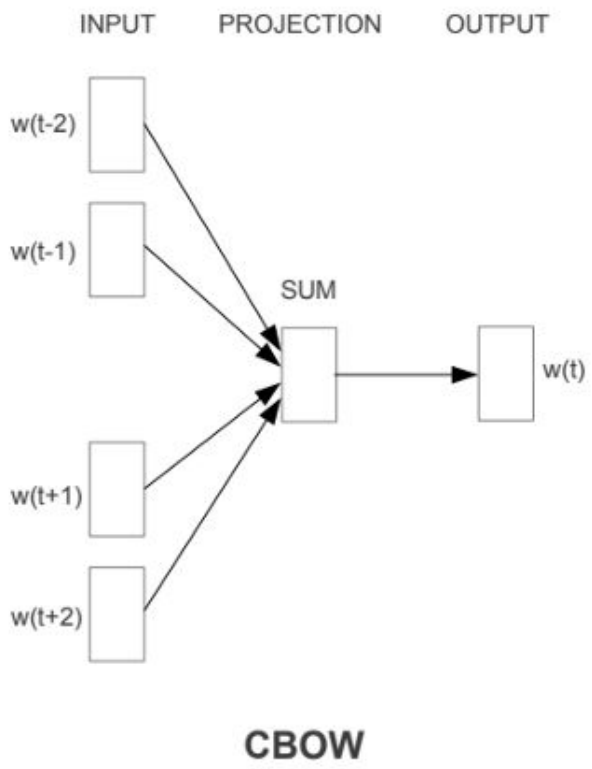

Continuous Bag of Words : Le modèle est nourri par le contexte et prédit le mot cible

Input : New _ City **Output** : York

Word2vec (Google,2013)

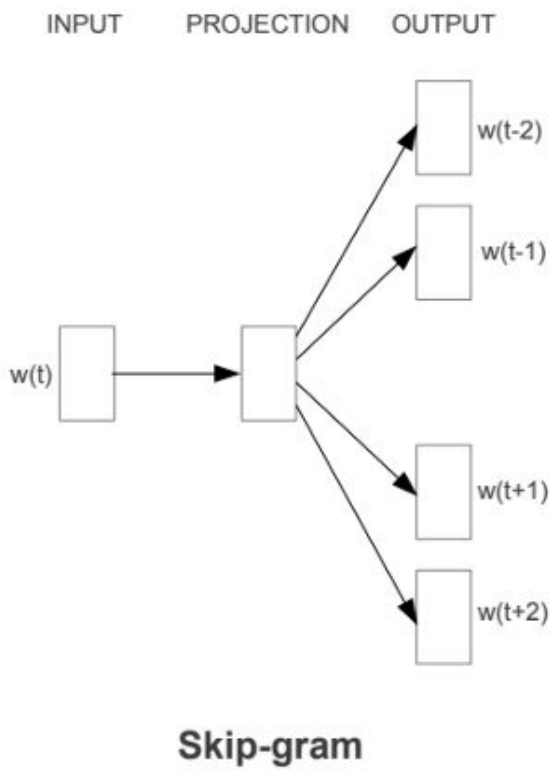

Skip-Gram : Le modèle prend un mot et prédit le contexte

Input : _ York _ **Output** : New _ City

Word2vec (Google,2013)

- Word2Vec demande un large corpus de texte et délivre un espace vectoriel de plusieurs centaines de dimensions, où chaque mot unique du corpus se voit assigné 1 vecteur
- La similarité sémantique se mesure par le cosinus entre 2 vecteurs
- Application à la traduction

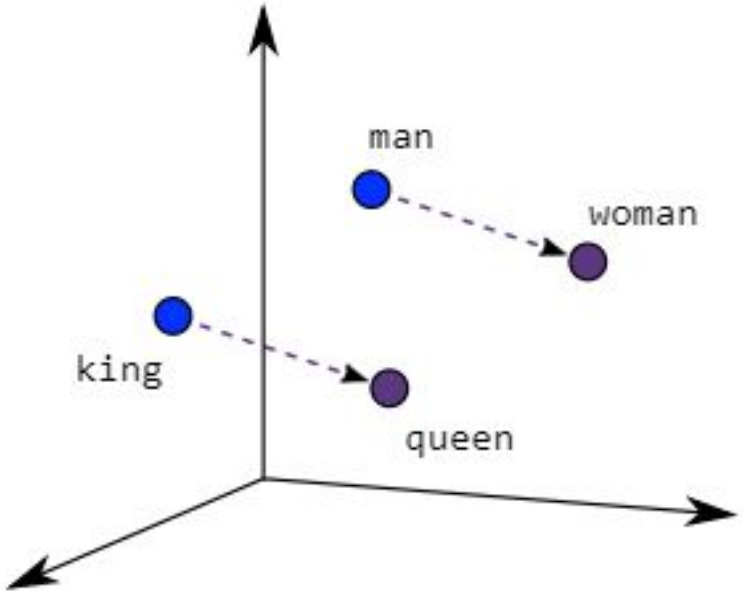

Roi – Homme + Femme = Reine

Les RNN

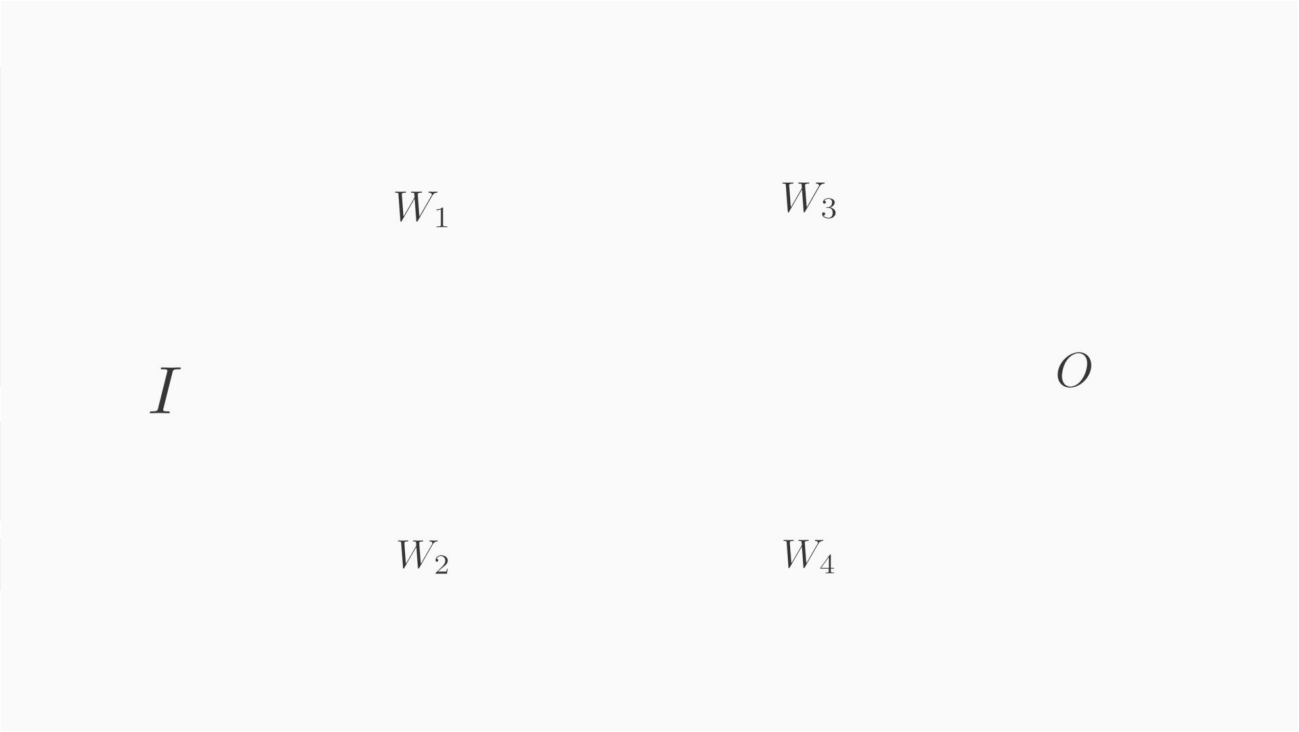

Les RNN

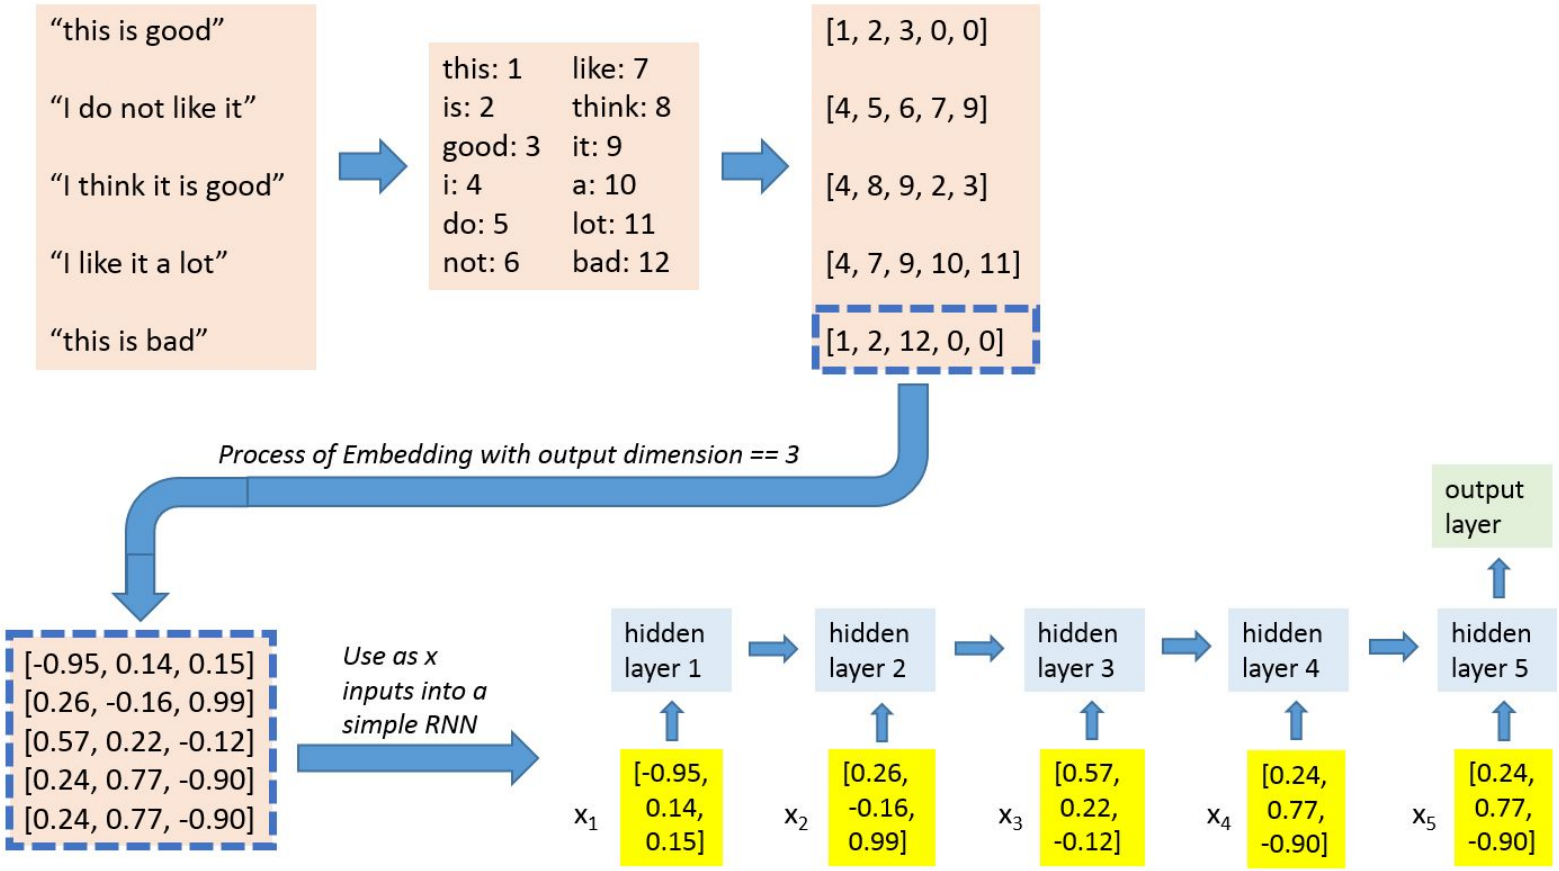
"this is good"
"I do not like it"
"I think it is good"
"I like it a lot"
"this is bad"
this: 1
is: 2
good: 3
i: 4
do: 5
not: 6
like: 7
think: 8
it: 9
a: 10
lot: 11
bad: 12
[1, 2, 3, 0, 0]
[4, 5, 6, 7, 9]
[4, 8, 9, 2, 3]
[4, 7, 9, 10, 11]
[1, 2, 12, 0, 0]
Process of Embedding with output dimension == 3
[-0.95, 0.14, 0.15]
[0.26, -0.16, 0.99]
[0.57, 0.22, -0.12]
[0.24, 0.77, -0.90]
[0.24, 0.77, -0.90]
Use as x inputs into a simple RNN
hidden layer 1
hidden layer 2
hidden layer 3
hidden layer 4
hidden layer 5
output layer
x1
[-0.95, 0.14, 0.15]
x2
[0.26, -0.16, 0.99]
x3
[0.57, 0.22, -0.12]
x4
[0.24, 0.77, -0.90]
x5
[0.24, 0.77, -0.90]

Les RNN

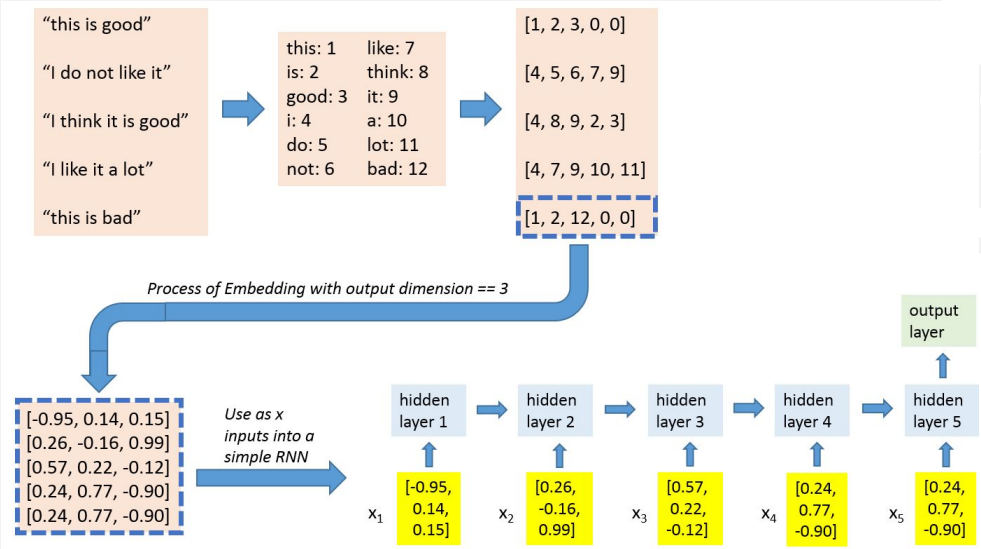

- **Contexte dynamique** : Word2Vec génère un vecteur statique pour chaque mot, indépendamment du contexte dans lequel il apparaît. Les RNN, en revanche, prennent en compte le contexte séquentiel, ce qui signifie que la représentation d'un mot peut changer en fonction des mots qui l'entourent.
- **Gestion de la dépendance à long terme** : Les RNN sont conçus pour gérer les dépendances à long terme dans les séquences de mots, ce qui est crucial pour comprendre des structures grammaticales complexes et des significations qui dépendent de segments plus larges du texte.
- **Meilleure compréhension des nuances** : En raison de leur capacité à analyser le contexte, les RNN peuvent mieux comprendre les subtilités telles que l'ironie, le sarcasme, et le ton, qui peuvent être perdus avec des modèles plus simples comme Word2Vec.

Introduction aux Transformers

- Un transformer est une architecture neuronale récurrente, comme les RNN, mais qui se repose sur le **mécanisme d'attention pour focaliser l'analyse du contexte sur les tokens les plus signifiants.**
- Contrairement aux RNN, les transformers **n'exigent pas que les données séquentielles soient traitées dans l'ordre**. Par exemple, si les données d'entrée sont une phrase en langage naturel, le transformer n'a pas besoin d'en traiter le début avant la fin. Grâce à cette fonctionnalité, le transformer permet une parallélisation beaucoup plus importante que les RNN et donc des temps d'entraînement réduits.

Introduction aux Transformers

- **Le mécanisme d’attention :** permet à un modèle de regarder directement, et d'extraire, l'état de n'importe quel jeton précédent dans la séquence.
- La couche d'attention peut accéder à tous les précédents états et leur donner un poids selon leur pertinence par rapport au jeton courant, fournissant ainsi une information saillante sur les jetons éloignés.
- Exemple : traduction d’une phrase en anglais vers le francais

Introduction aux Transformers

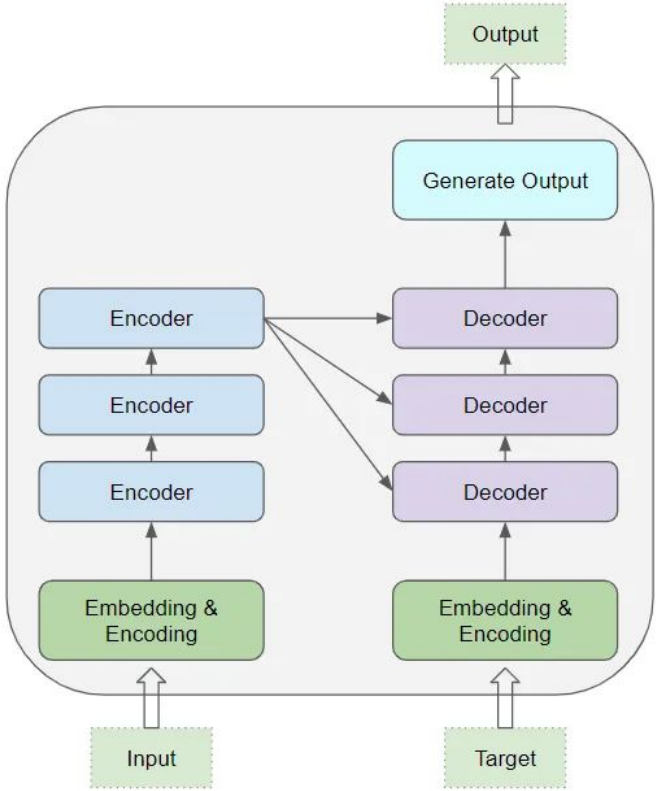

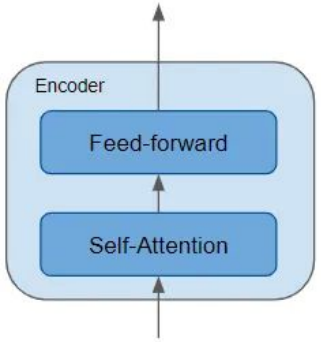

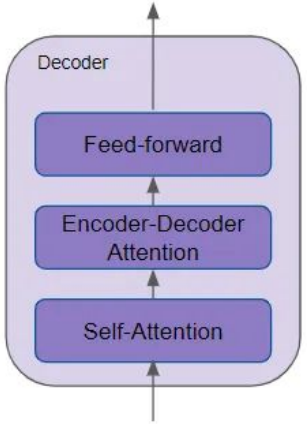

Introduction aux Transformers

The cat drank the milk because it was hungry
The cat drank the milk because it was sweet

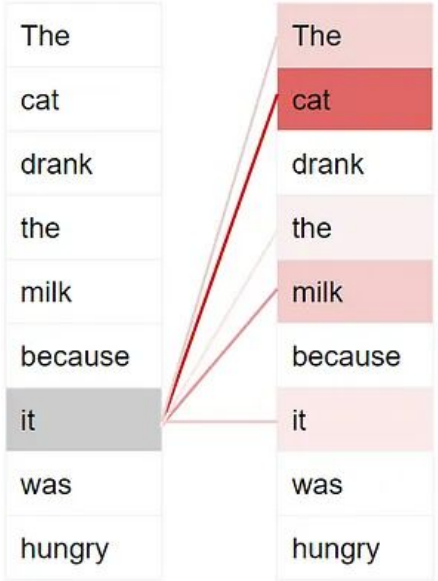

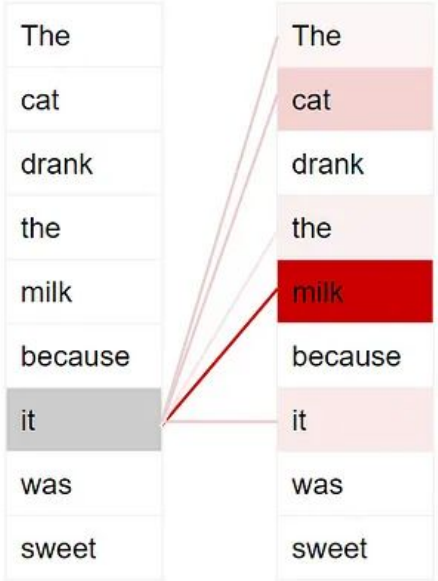

Résumé rapide

Deep Learning

Word2Vec : CNN à 1 couche, premier Word Embedding réellement efficace et crédible

RNN/LSTM : Structure récursive, conserve mieux l'info dans les grandes séquences et fournit un embedding dynamique en fonction du contexte

Transformers : Introduction du mécanisme d'attention qui focalise sur les termes importants, ce qui accélère les calculs et permet leur parallélisation

Un aperçu d'un LLM : Bert
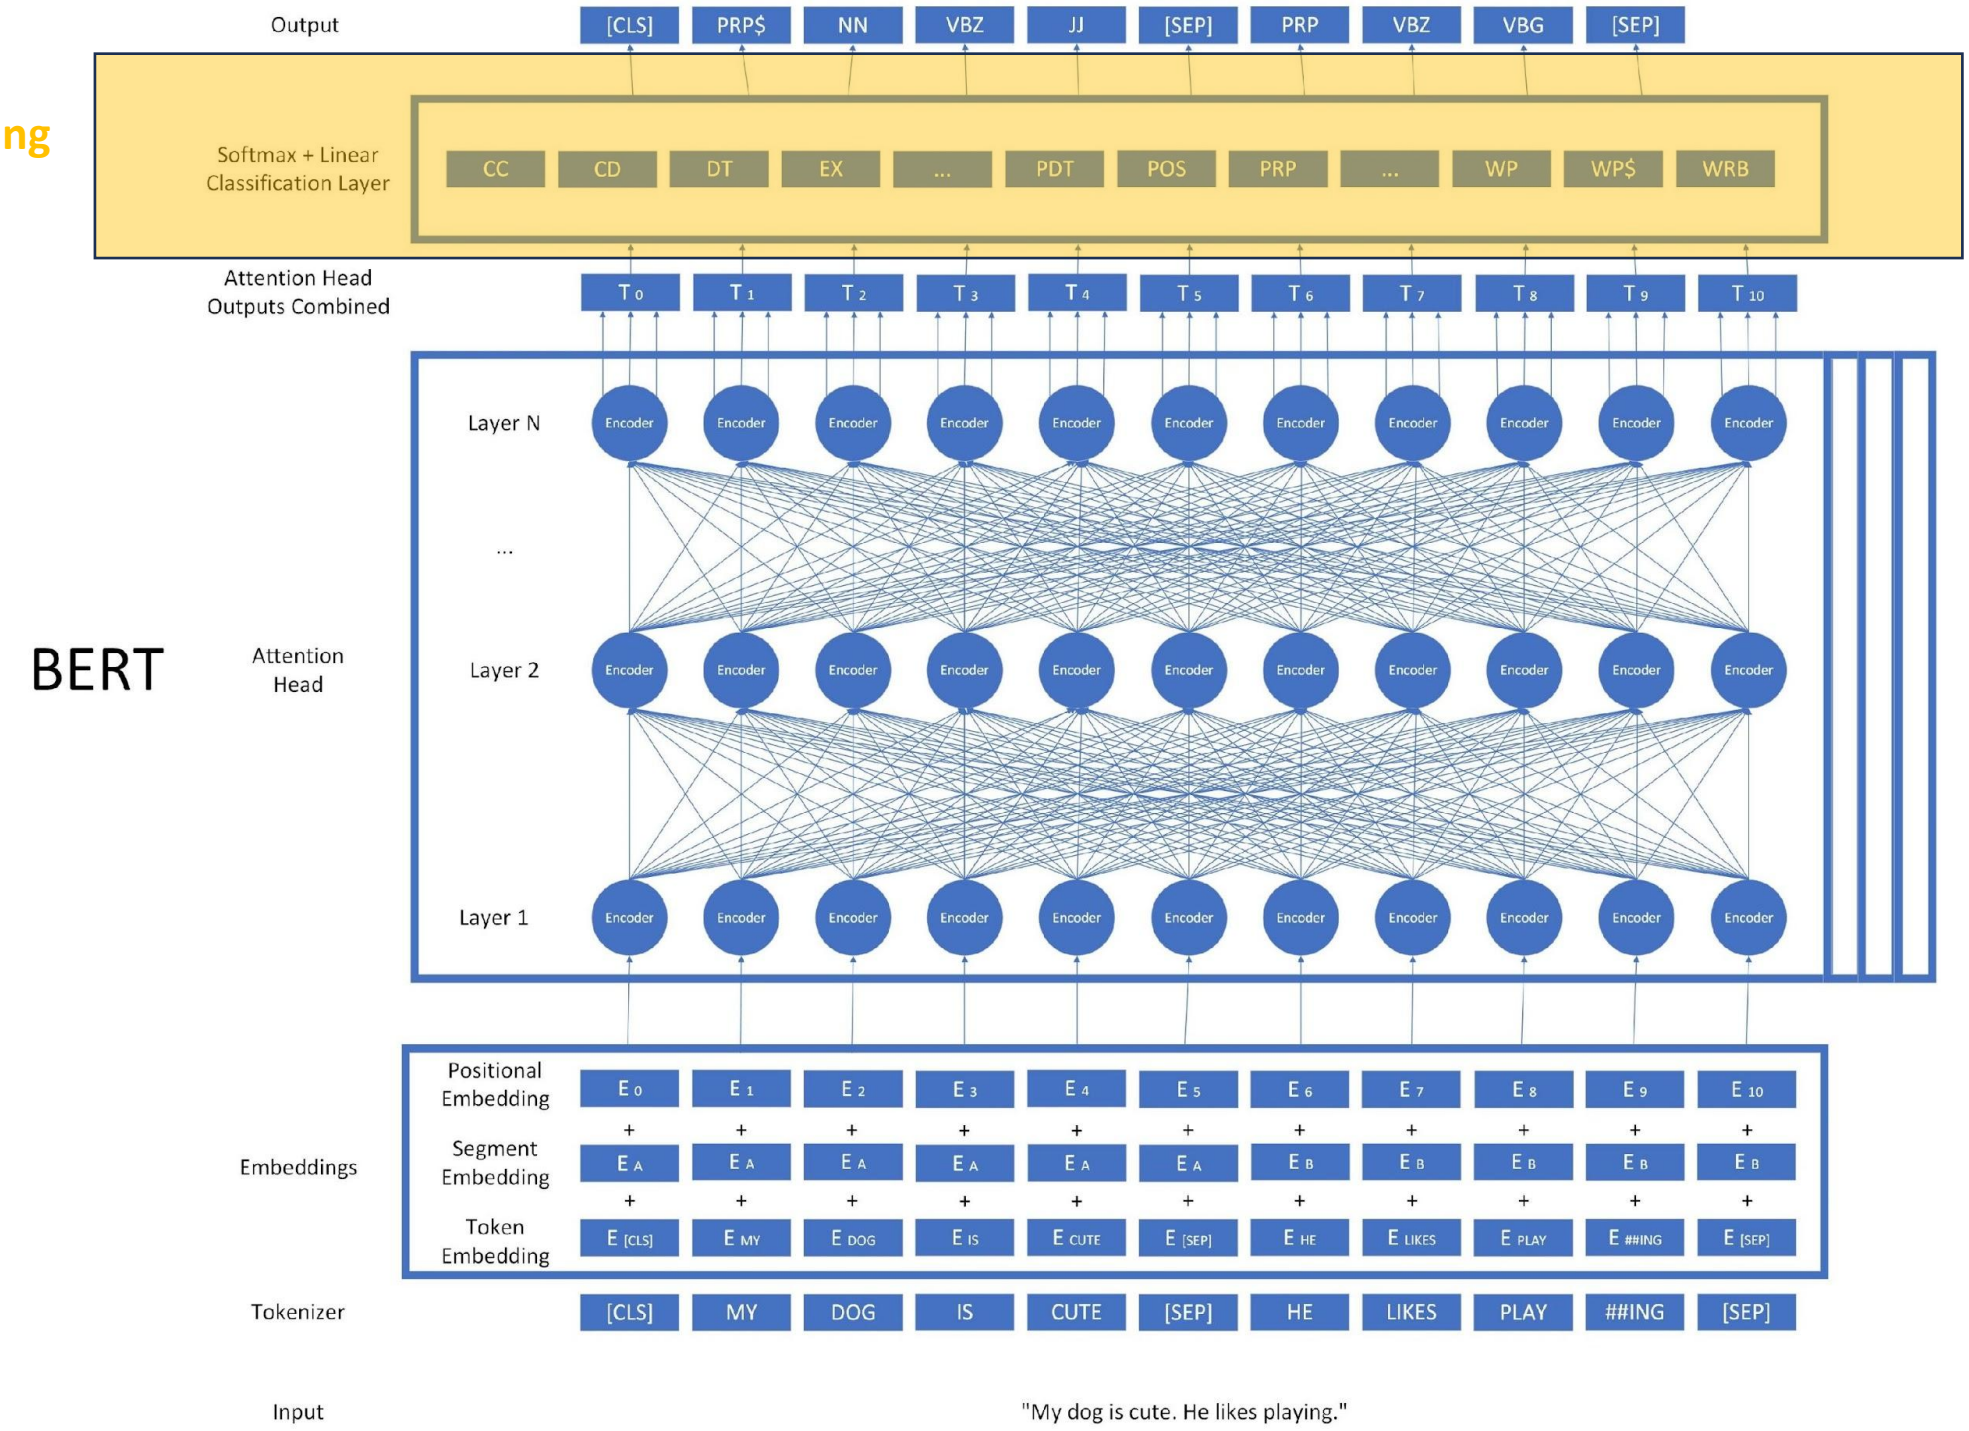
Fine Tuning